Capacity Metric App per Microsoft Fabric

Marco Pozzan
CTO
Regolo Farm

DATA SATURDAYS

Innova community

Sponsors

UNIPORDENONE
moltiplica il valore della formazione

Règolo FARM

DATA SATURDAYS

DATA SATURDAYS

- *Fondatore e CTO Regolo Farm azienda di Business Intelligence e Artificial Intelligence*
- *Fondatore e CTO Cargo BI software di analisi campo assicurativo*
- ***Fondatore community di 1nn0va che porto avanti con il vero instancabile motore Marco Parenzan***
- *Docente all'Università di Pordenone per i corsi IFTS di analisi Big Data e Implementazione di data warehouse*
- *MCP,MCSA,MCSE dal 2017 MCT e dal 2014 MVP per SQL Server 2016 MVP Power BI e dal 2022 MVP Fabric e relatore in diverse conferenze sul tema.*

MVP Microsoft Most Valuable Professional

Microsoft CERTIFIED AZURE DATA ENGINEER ASSOCIATE

Microsoft CERTIFIED Trainer

Microsoft CERTIFIED Professional

Marco.pozzan@regolofarm.com
@marcopozzan.it (linked-in)
@regolo farm (linked-in)
www.marcopozzan.it

1nn0va community

CONSORTIVM SERVICE S.r.l.

UNIPORDENONE moltiplica il valore della formazione

Agenda

- Cosa sono le CU
- Allocazione Dinamica
  - Bursting
  - Smoothing
- Throttling
- Capacity Metric App
- Altri meccanismi di Resource Governator
- Guida alla pianificazione della capacità

Cosa sono le CU

- Fabric risiede in una capacità che è un pool di risorse allocate

- Ogni capacità ha il proprio numero di unità di capacità (CU) che misurano la potenza di calcolo disponibile per la capacità CPU, memoria e I/O su disco allocate dalle attività)

Una volta completata un'operazione , il tempo di esecuzione viene raccolto, valutato e **aggregato** in cicli di valutazione (intervalli), **dove ogni ciclo è composto da 30 secondi**

Esempio una F64 x 30 = 1920 Unità di capacità secondi [CU(s)].

Cosa sono le CU

- Molte operazioni misurano **il consumo in base alla durata**, altre, come Copilot utilizza il **numero di token elaborati** per chiamata.

- Bisogna converitre il contatore nativo in CU per rimanere coerenti. Esempio: 2.000 token di input e 500 token di output. (400 secondi CU per 2.000 token di input e 1.200 secondi CU per 500 token di output).

CU rispetto alle SKU

SKU	Capacity Units (CU)	Power BI SKU	Power BI v-cores
F2	2	-	0.25
F4	4	-	0.5
F8	8	EM/A1	1
F16	16	EM2/A2	2
F32	32	EM3/A3	4
F64	64	P1/A4	8
F128	128	P2/A5	16
F256	256	P3/A6	32
F512	512	P4/A7	64
F1024	1024	P5/A8	128
F2048	2048	-	256

Capacity	CU's per Second	CU's per Half-Minute	CU's per Day
F2	2	60	172,800
F4	4	120	345,600
F8	8	240	691,200
F16	16	480	1,382,400
F32	32	960	2,764,800
F64	64	1,920	5,529,600
F128	128	3,840	11,059,200
F256	256	7,680	22,118,400
F512	512	15,360	44,236,800
F1024	1,024	30,720	88,473,600
F2056	2,056	61,680	177,638,400

Tradurre i CU in costi

- pagamento in base al consumo: esempio Stati Uniti occidentali, 1 ora di CU costa $ 0,18. Per uno SKU F2: Costo mensile (**pagamento in base al consumo**): $ 0,18 * 730ore = $ 131,40. Di conseguenza, uno SKU F2 costa $ 131,40 * 2 = **$ 262,80**.

- Per le istanze riservate: l'impegno a un livello di SKU di 12 mesi offre risparmi significativi (~40,5% rispetto alle tariffe pagate in base al consumo), calcolati come segue: Costo mensile (**istanza riservata** per SKU F2): Arrotondamento ($ 0,18 * (1-0,405) * 730 * 12) / 12 = ~$ 78,166 * 2 CU = **~$ 156,334**. Questo modello garantisce che la fatturazione sia trasparente, prevedibile e adattabile ai tuoi modelli di utilizzo.

Costi per SKU

SKU	Capacity unit (CU)	Pay-as-you-go (monthly)	Reservation (monthly) *~40.5% saving over Pay-as-you-go*
F 2	2	$262.8	$156.334
F 4	4	$525.6	$312.667
F 8	8	$1,051.2	$625.334
F 16	16	$2,102.4	$1,250.667
F 32	32	$4,204.8	$2,501.334
F 64	64	$8,409.6	$5,002.667
F 128	128	$16,819.2	$10,005.334
F 256	256	$33,638.4	$20,010.667
F 512	512	$67,276.8	$40,021.334
F 1024	1024	$134,553.6	$80,042.667
F 2048	2048	$269,107.2	$160,085.334

Agenda

- Cosa sono le CU
- Allocazione Dinamica
  - Bursting
  - Smoothing
- Throttling
- Capacity Metric App
- Altri meccanismi di Resource Governator
- Guida alla pianificazione della capacità
- Throttling

Allocazione dinamica risorse

- **L'essenza di Fabric è la sua natura dinamica e flessibile**, che consente l'adattamento delle risorse in risposta al carico di lavoro e ai modelli di utilizzo.

- Questa allocazione dinamica significa che **l'utilizzo delle risorse può essere aumentato** o **ridotto in base alla domanda in tempo reale**, garantendo di beneficiare dell'elasticità e della scalabilità del cloud.

- Microsoft Fabric Capacity rappresenta un'innovazione nella gestione **efficiente** ed **efficace** delle soluzioni dati, **garantendo agli utenti di sfruttare appieno il potenziale del cloud senza la necessità di complesse strategie di gestione delle risorse**.

Bursting (scoppio)

- Per garantire le prestazioni veloci Microsoft Fabric usa il meccanismo del **bursting** in modo tale che le operazioni siano più veloci possibili e **consente di utilizzare più CU rispetto a quelle assegnate da SKU di capacità**

- Ovviamente per fare questo userà più capacità di quanto noi ne abbiamo.

- Dobbiamo pensare al **Bursting come un prestito in banca**. Quando Fabric ha bisogno di più CU per il suo compito chiede un prestito che poi ritornerà (ne parleremo)

Esempio di busting

- Ad esempio, immagina di utilizzare un notebook con una capacità F2. **Il notebook consuma 20.000 CU**.

- l'esecuzione di un'operazione da 20.000 CU su una capacità F2 dovrebbe richiedere 10.000 secondi (2,8 ore). Tuttavia, raddoppiando le risorse disponibili, la stessa operazione potrebbe essere completata in 5.000 secondi (1,4 ore).

- L'equazione di fatturazione non è cambiata: l'operazione consuma ancora lo stesso numero di CU, ma grazie alla magia del bursting, l'operazione viene completata nella metà del tempo.

Bursting e i suoi limiti

- Il burst è subordinato alla disponibilità delle risorse all'interno del pool,
- viene influenzato dalla domanda complessiva e dalla capacità inutilizzata degli altri. Pertanto la sua disponibilità non può essere garantita in ogni momento.
- La tabella seguente mostra i limiti SKU per la capacità

Fabric SKU	Equivalent Premium SKU	Baseline Capacity Units (CU)	Burstable Scale Factor
F2		2	1x - 32x
F4		4	1x - 16x
F8		8	1x - 12x
F16		16	1x - 12x
F32		32	1x - 12x
F64	P1	64	1x - 12x
F128	P2	128	1x - 12x
F256	P3	256	1x - 12x
F512	P4	512	1x - 12x
F1024	P5	1024	1x - 12x
F2048		2048	1x - 12x

Smoothing (livellamento)

- Evita di penalizzare gli utenti quando le operazioni usano il bursting infatti **con lo smoothing si consente una pianificazione su un arco di tempo più lungo della capacità** basata sull'utilizzo medio anziché sui picchi. Questo garantisce che picchi improvvisi di domanda non compromettano l'efficienza o le prestazioni

- Quindi possiamo dire che lo **smoothing distribuisce l'utilizzo della CU nel futuro questi unità** di tempo si chiamano «**punti di tempo futuri**» che sono di 30 secondi. Nelle 24 ore successive abbiamo quindi
  - **punto di tempo futuri 30 secondi**
  - **(2 punti di tempo futuri = 1 minuto) * 60 = 120 punti in un ora**
  - **(120 *24) = 2880 punti a disposizione**

Tipo di operazione

- Le operazioni **interattive** e in **background**, ciascuna delle quali supporta attività specifiche e viene gestita in modo diverse:
- **Le operazioni interattive** sono attività on-demand avviate dalle interazioni dell'utente, tramite l'interfaccia utente di Fabric o interfacce esterne come SSMS. A queste operazioni vengono **assegnate risorse di elaborazione on-demand**, in base alla frequenza e al numero di richieste dell'utente.
- **Le operazioni in background** sono attività come aggiornamenti pianificati dei dati o processi di pipeline dati che vengono eseguiti senza l'interazione immediata dell'utente. **A queste operazioni vengono allocate risorse di calcolo in anticipo** e sono progettate per garantire affidabilità e coerenza.

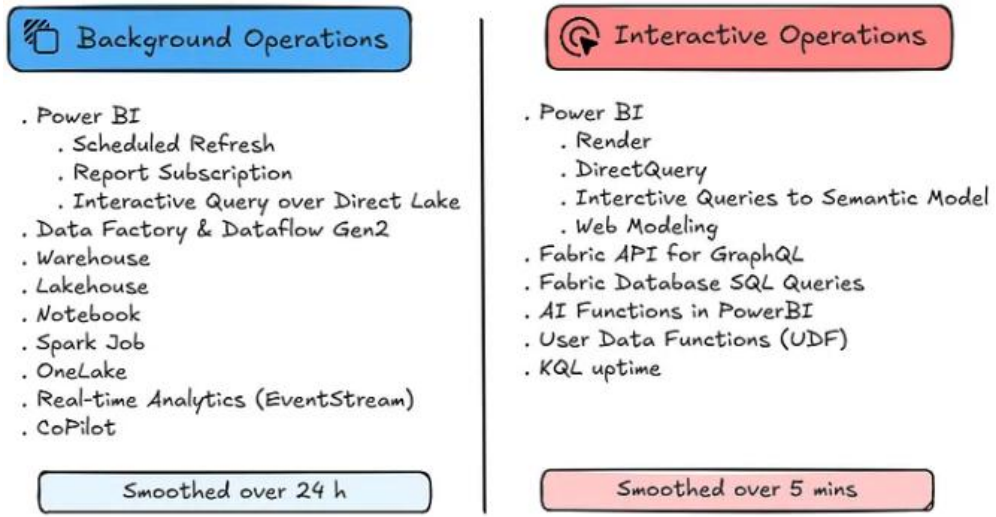

Tipi diverso di Smoothing

- **Le tecniche di livellamento variano in base al tipo di job.**

- **Per i job interattivi** avviati dagli utenti, la domanda di **capacità viene in genere distribuita su una finestra temporale di 5 minuti per mitigare i picchi** a breve termine (contrasta il bursting interattivo)

- **Per i job pianificati o in background**, la domanda **viene (automaticamente) distribuita su 24 ore, eliminando così conflitti di pianificazione e problemi di contesa**. Questo processo non influisce sui tempi di esecuzione, che rimangono ottimali. (Contrasta il bursting di background)

Esempio di background smoothing

- Esempio di prima di un notebook con una capacità F2. **Il notebook consuma 20.000 CU**. Se tutte le CU raggiungessero la capacità contemporaneamente, la sovraccaricherebbero completamente (**un F2 ha solo 60 CU disponibili ogni mezzo minuto**).
- Per evitare automaticamente questo sovraccarico, **Fabric divide le CU per quel notebook per 2.880 (il numero di mezzi minuti in 24 ore) e, invece di caricare 20.000 unità in una volta sola, la capacità viene caricata a 6,94 CU per mezzo minuto per le successive 24 ore**.

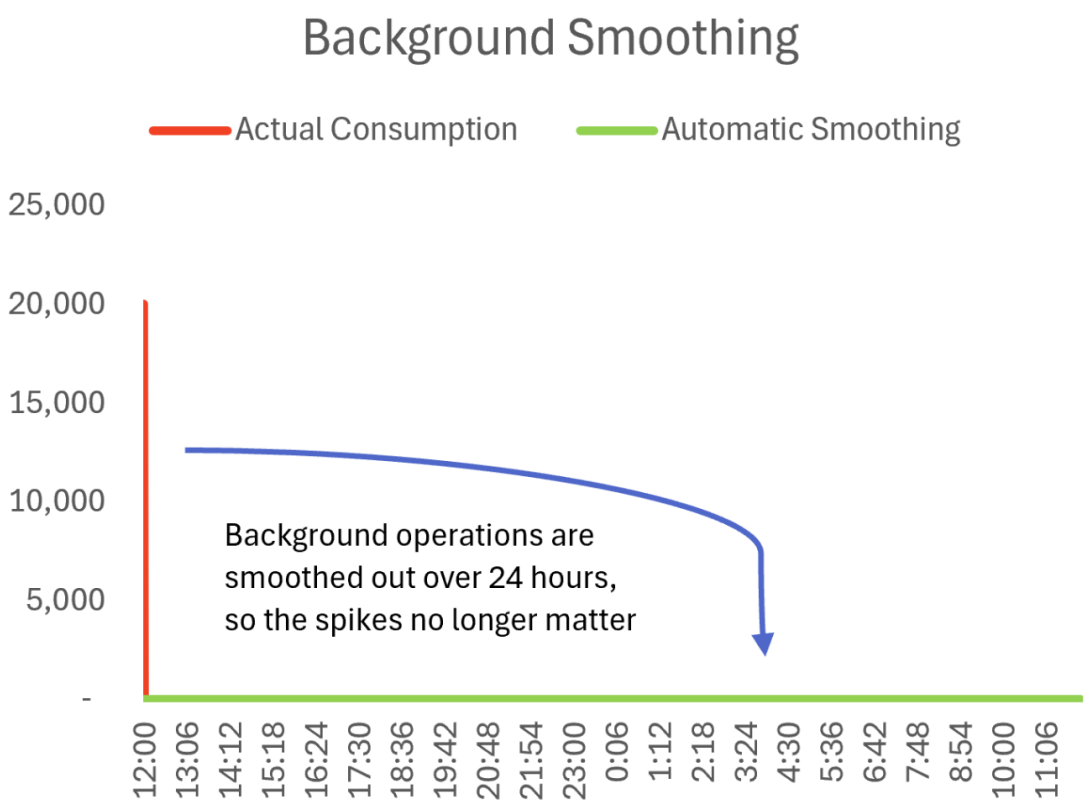

Inizio caricamenti alle 00:00

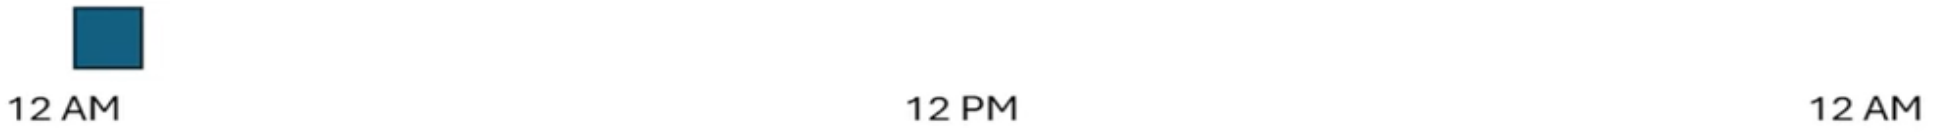

Caricamenti aumentano parte bursting

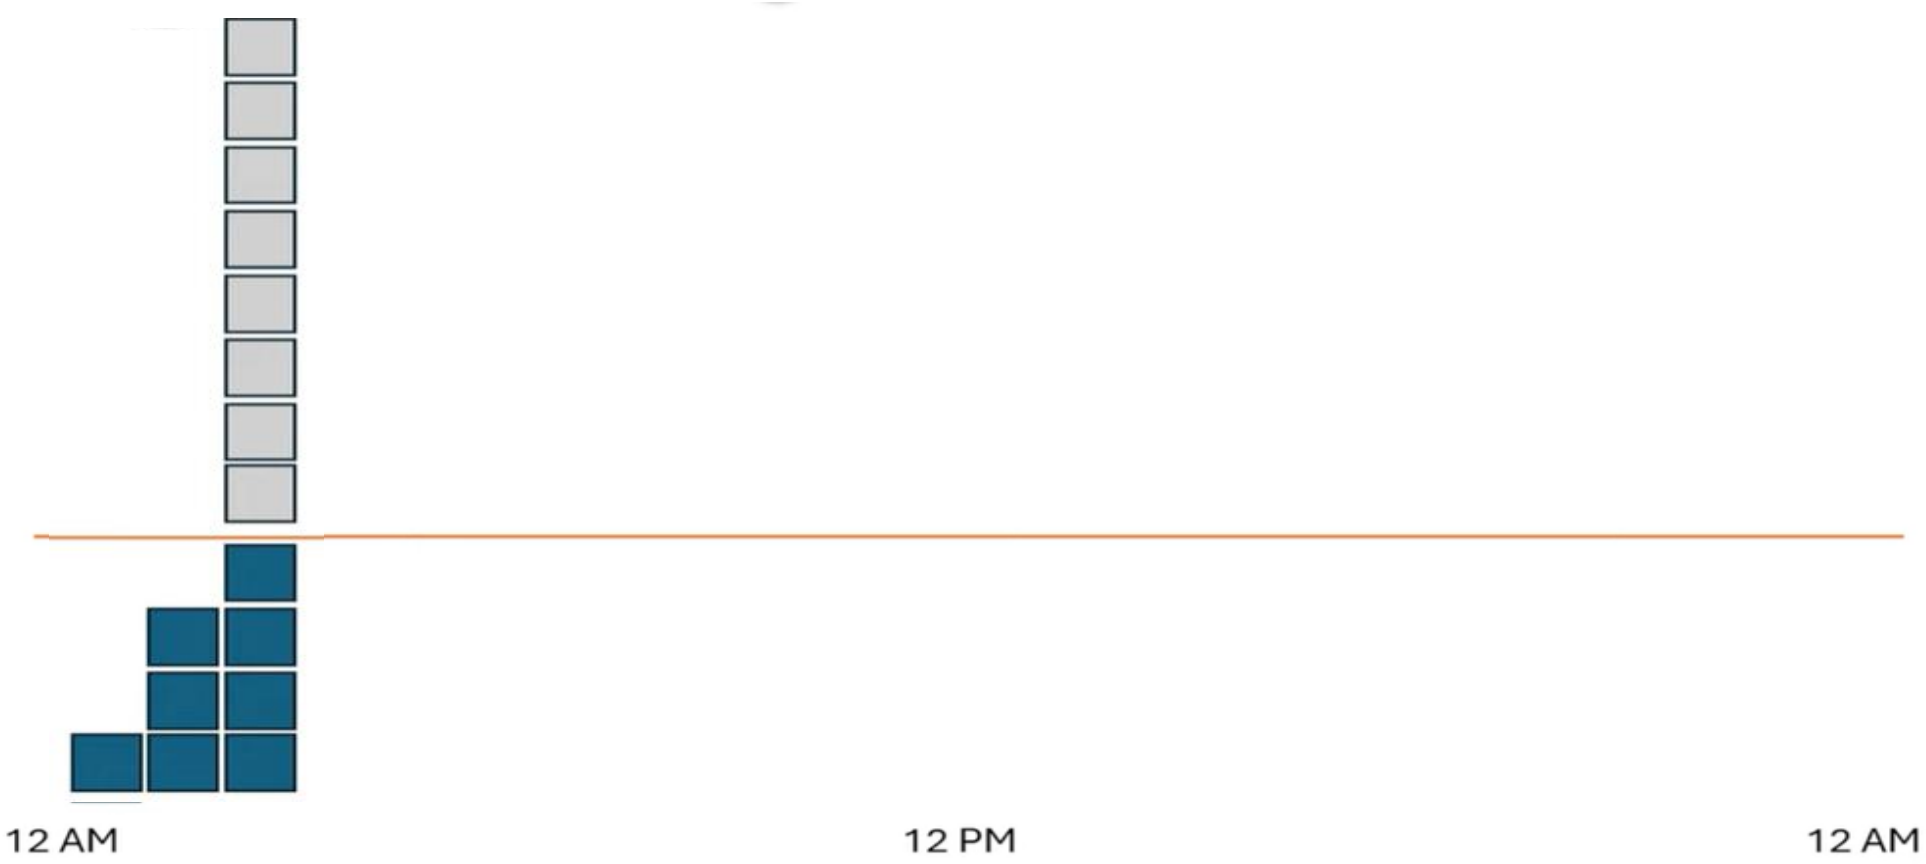

Bursting continua fino alle 5:00

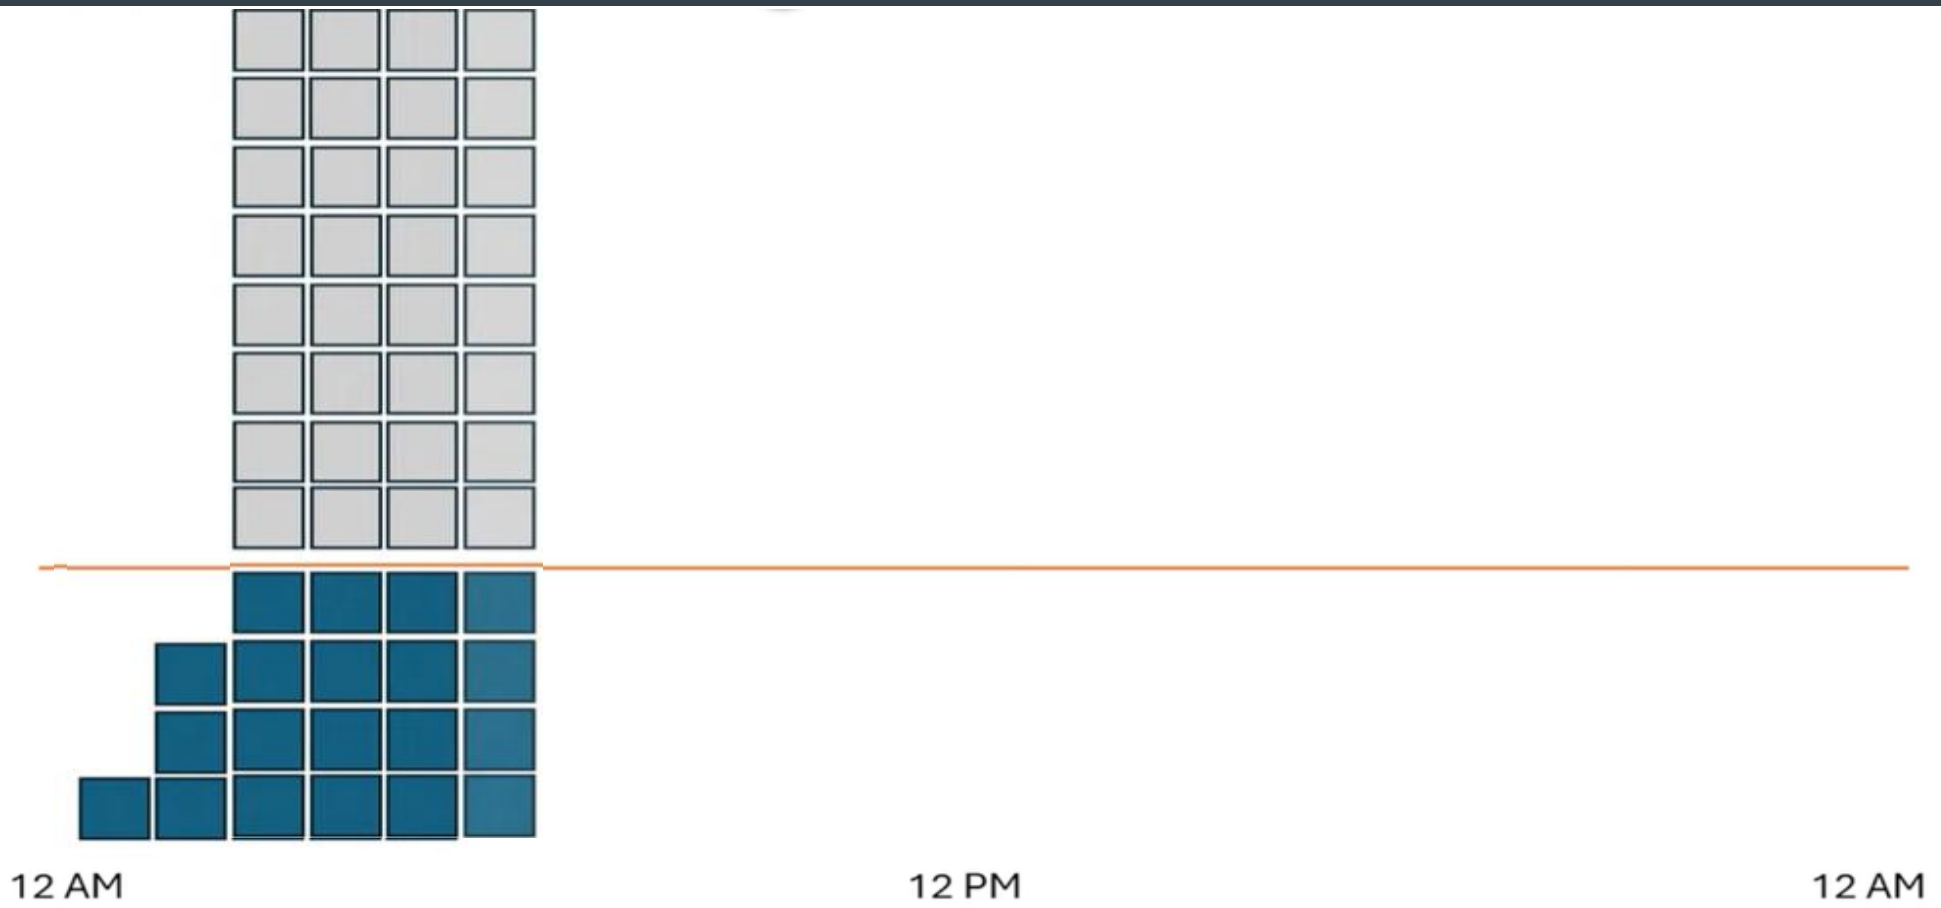

Bursting finisce alle 6:00 parte smoothing

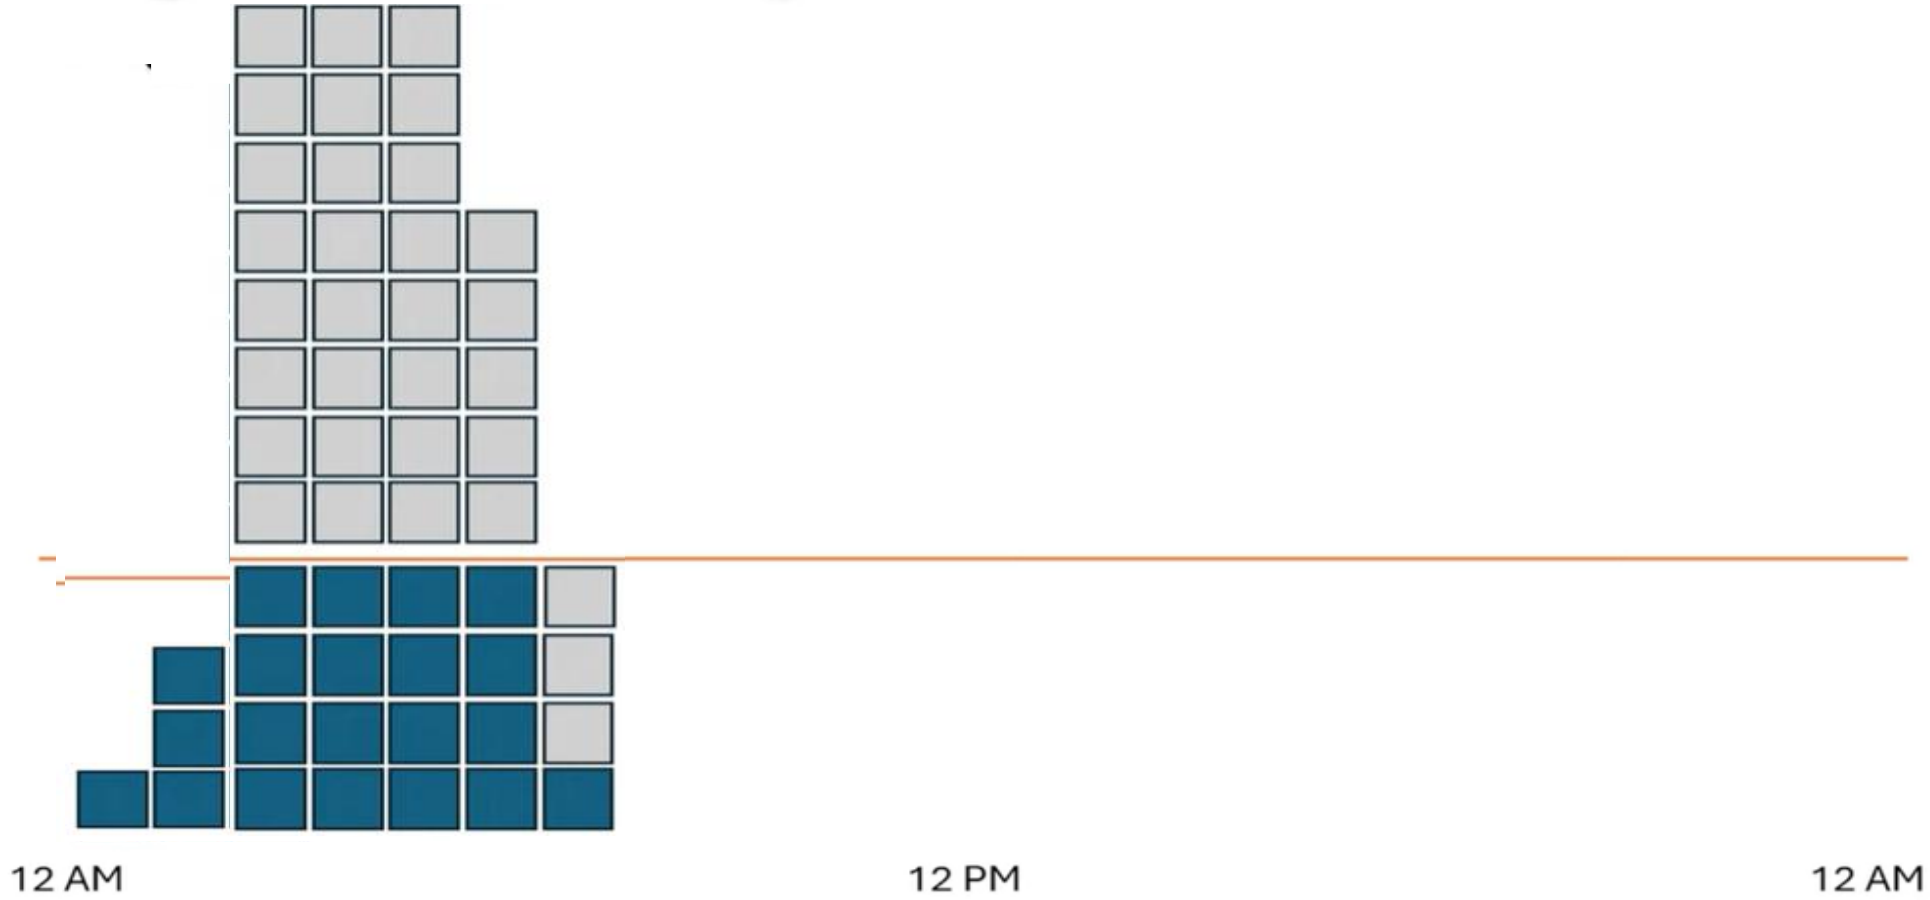

lo smoothing continua fino alle 8:00

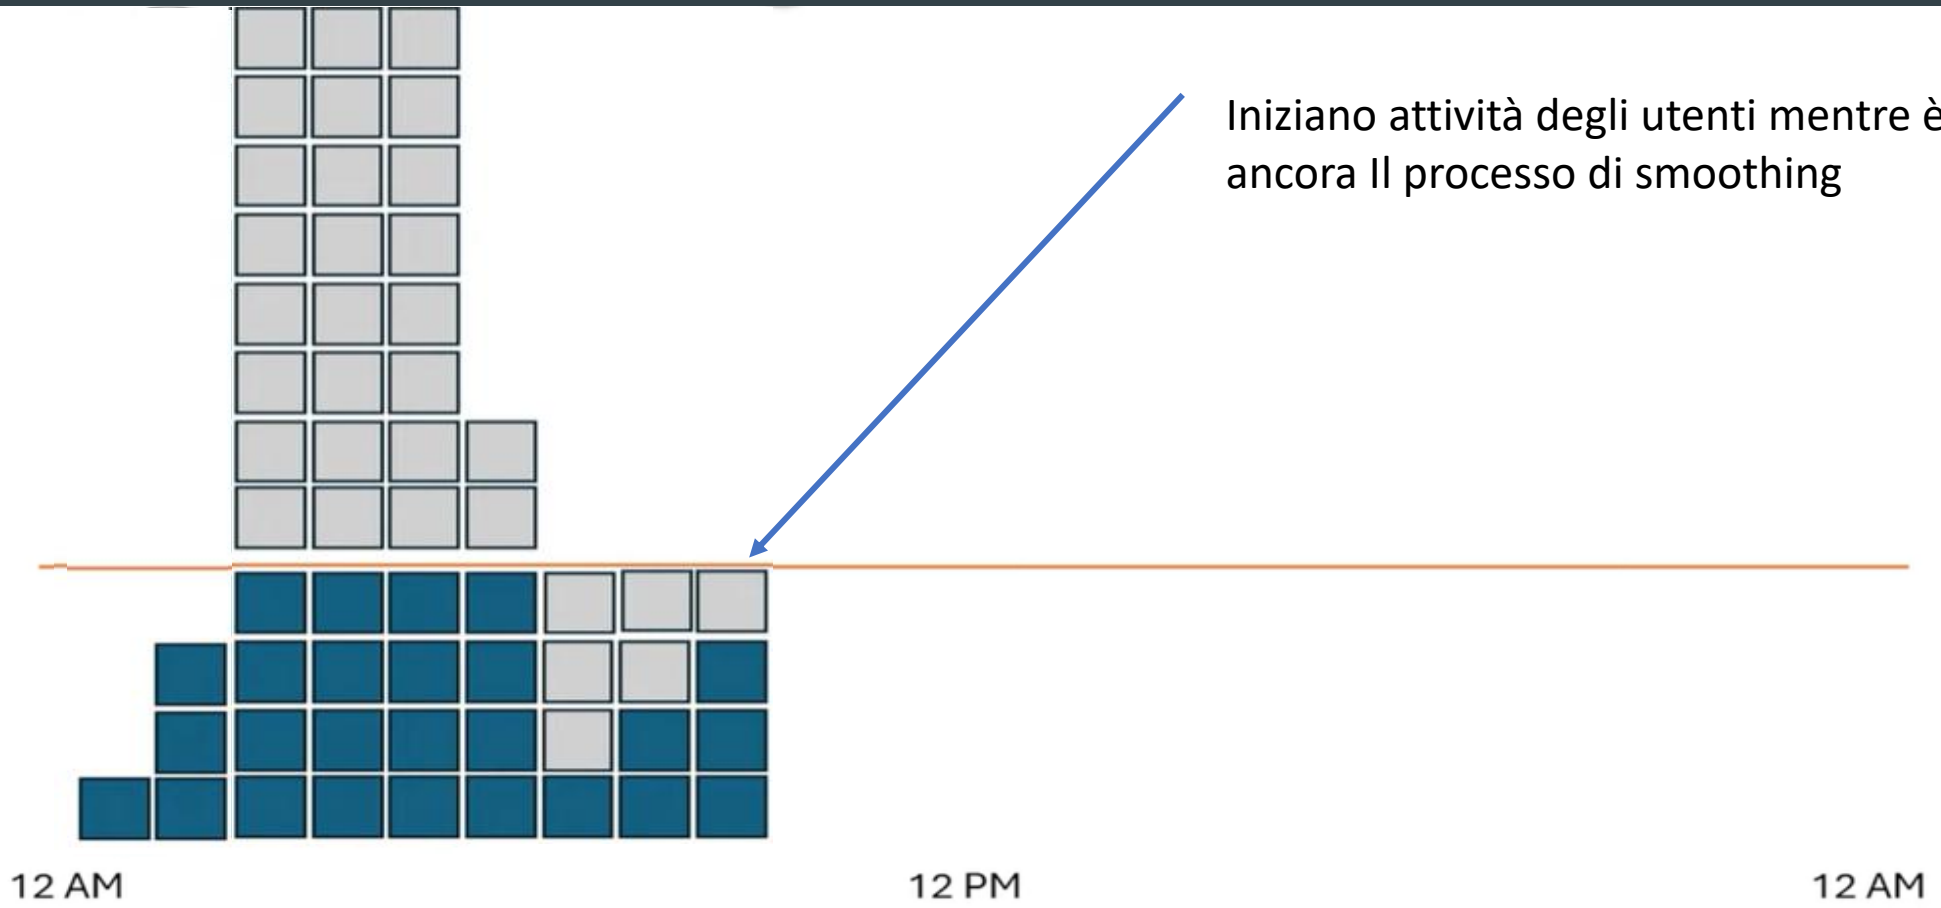

Iniziano attività degli utenti mentre è in atto ancora Il processo di smoothing

lo smoothing continua fino alle 9:00

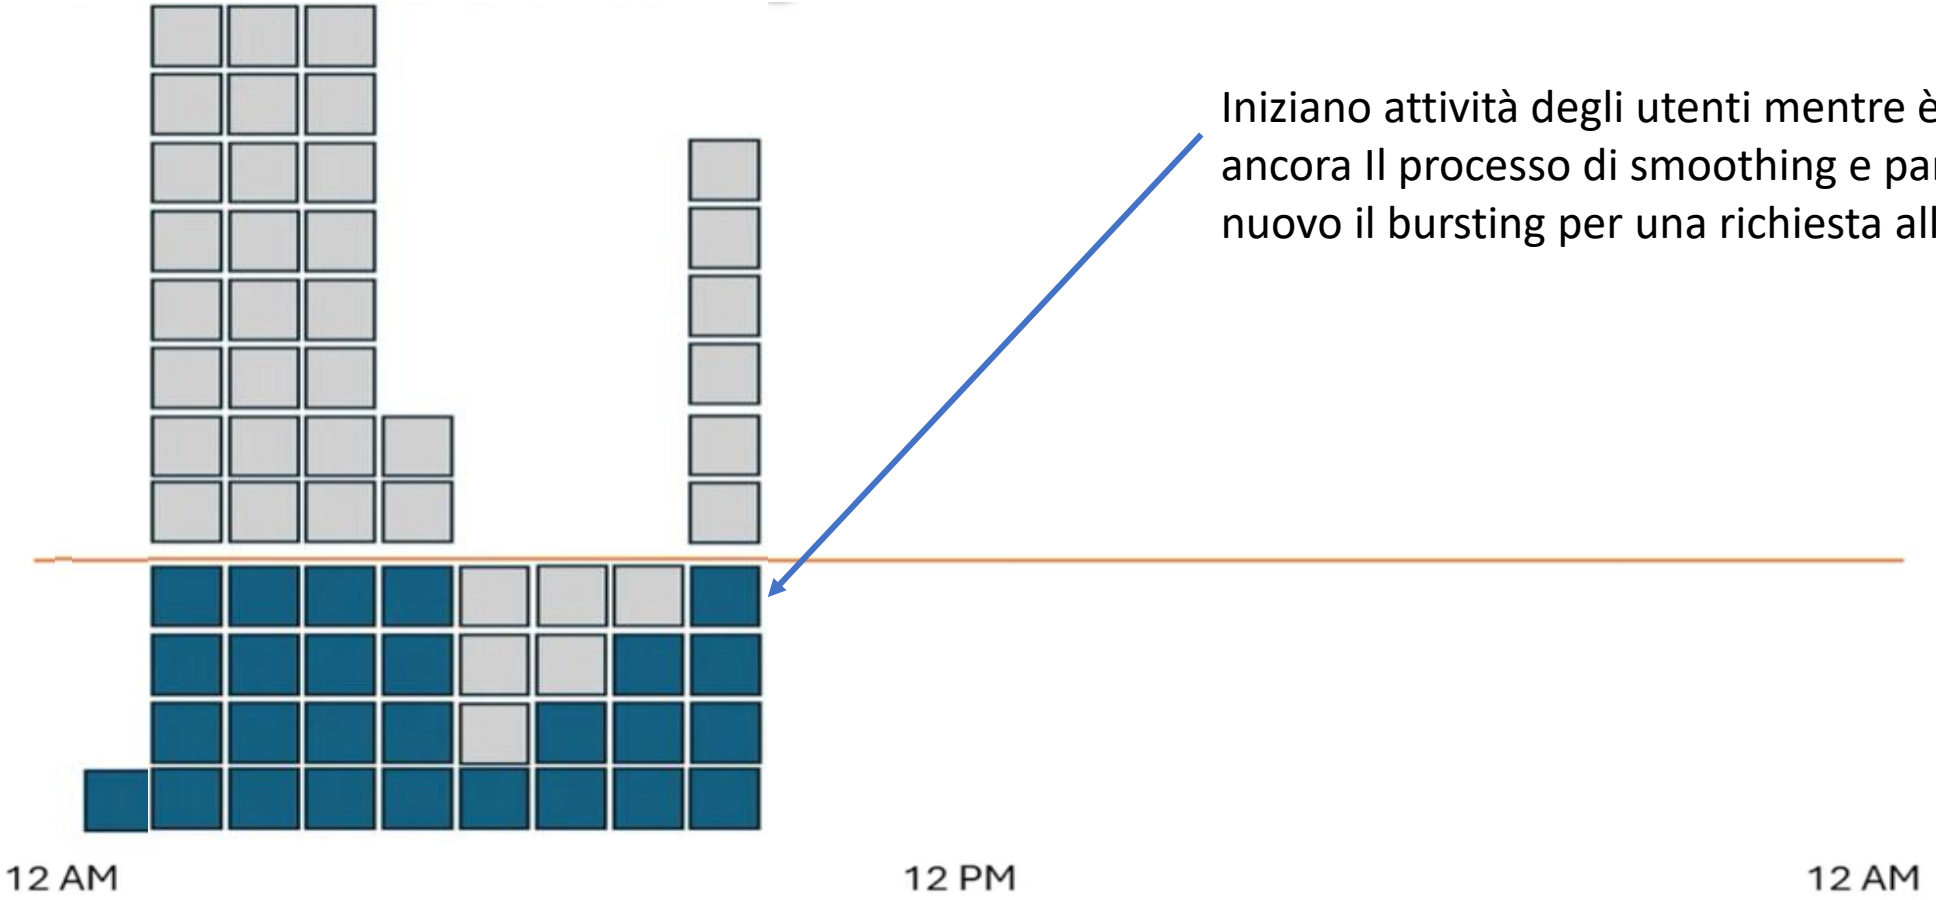

Iniziano attività degli utenti mentre è in atto ancora Il processo di smoothing e parte di nuovo il bursting per una richiesta alle 9:00

lo smoothing continua fino alle 14:00

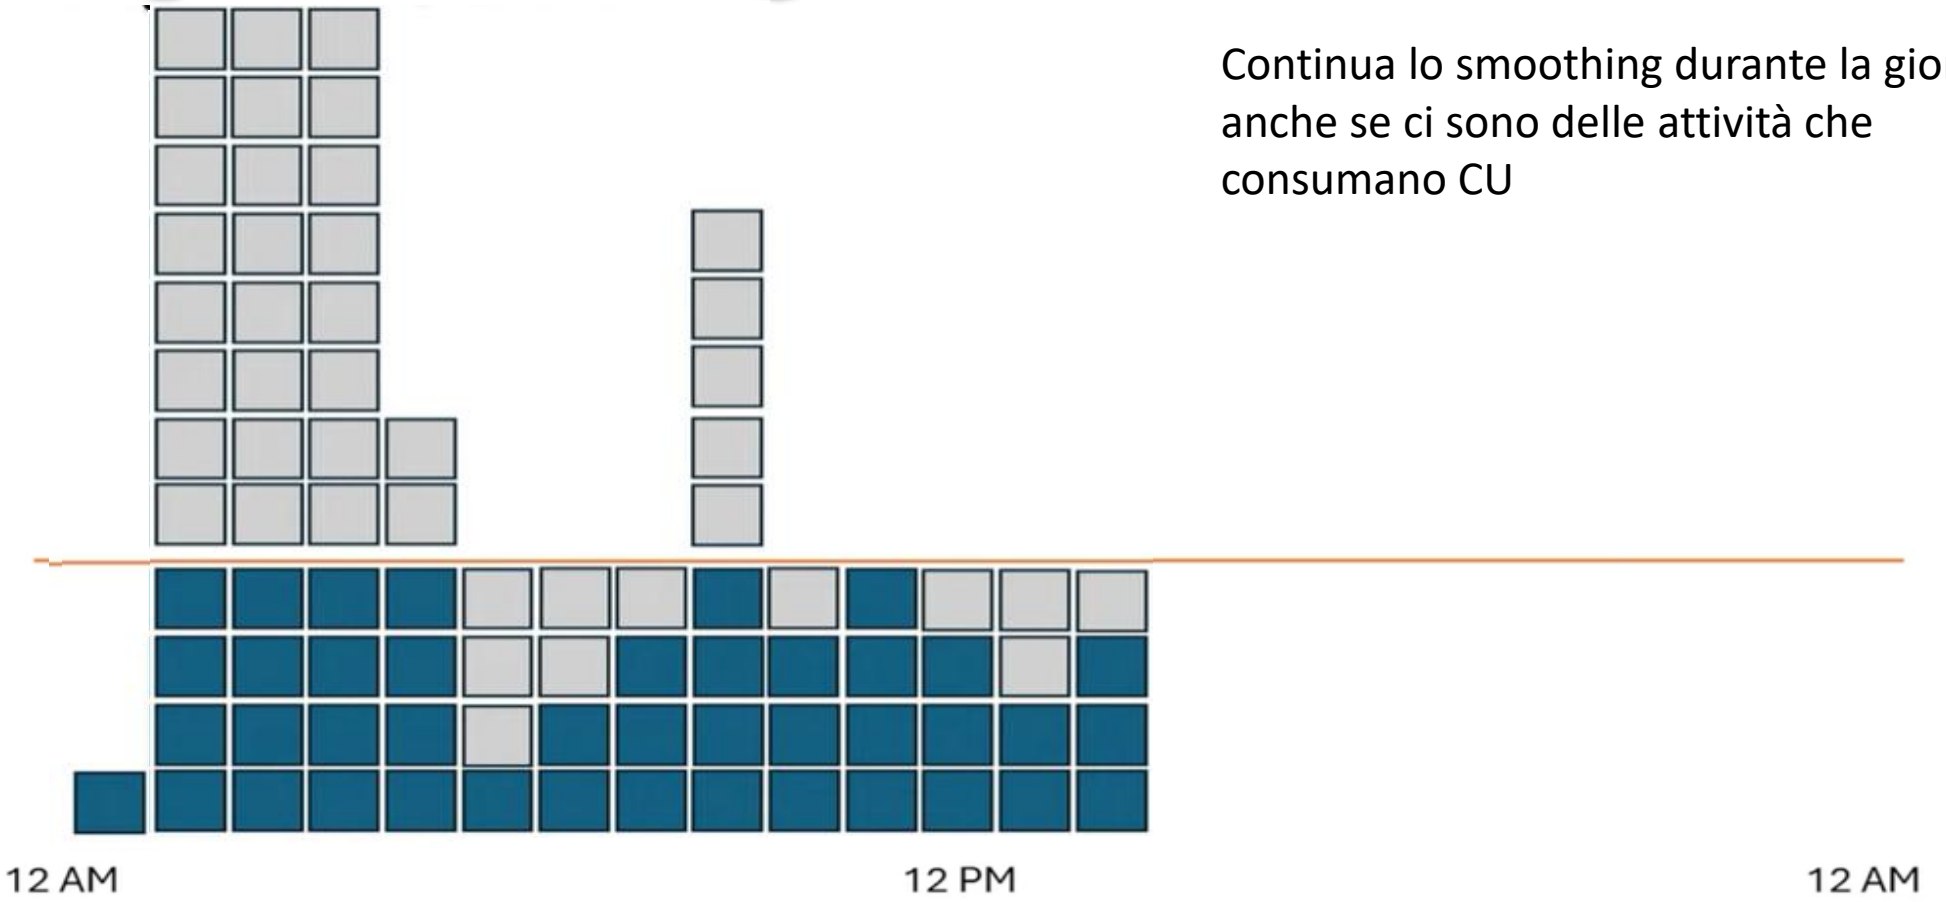

Continua lo smoothing durante la giornata anche se ci sono delle attività che consumano CU

lo smoothing continua fino alle 17:00

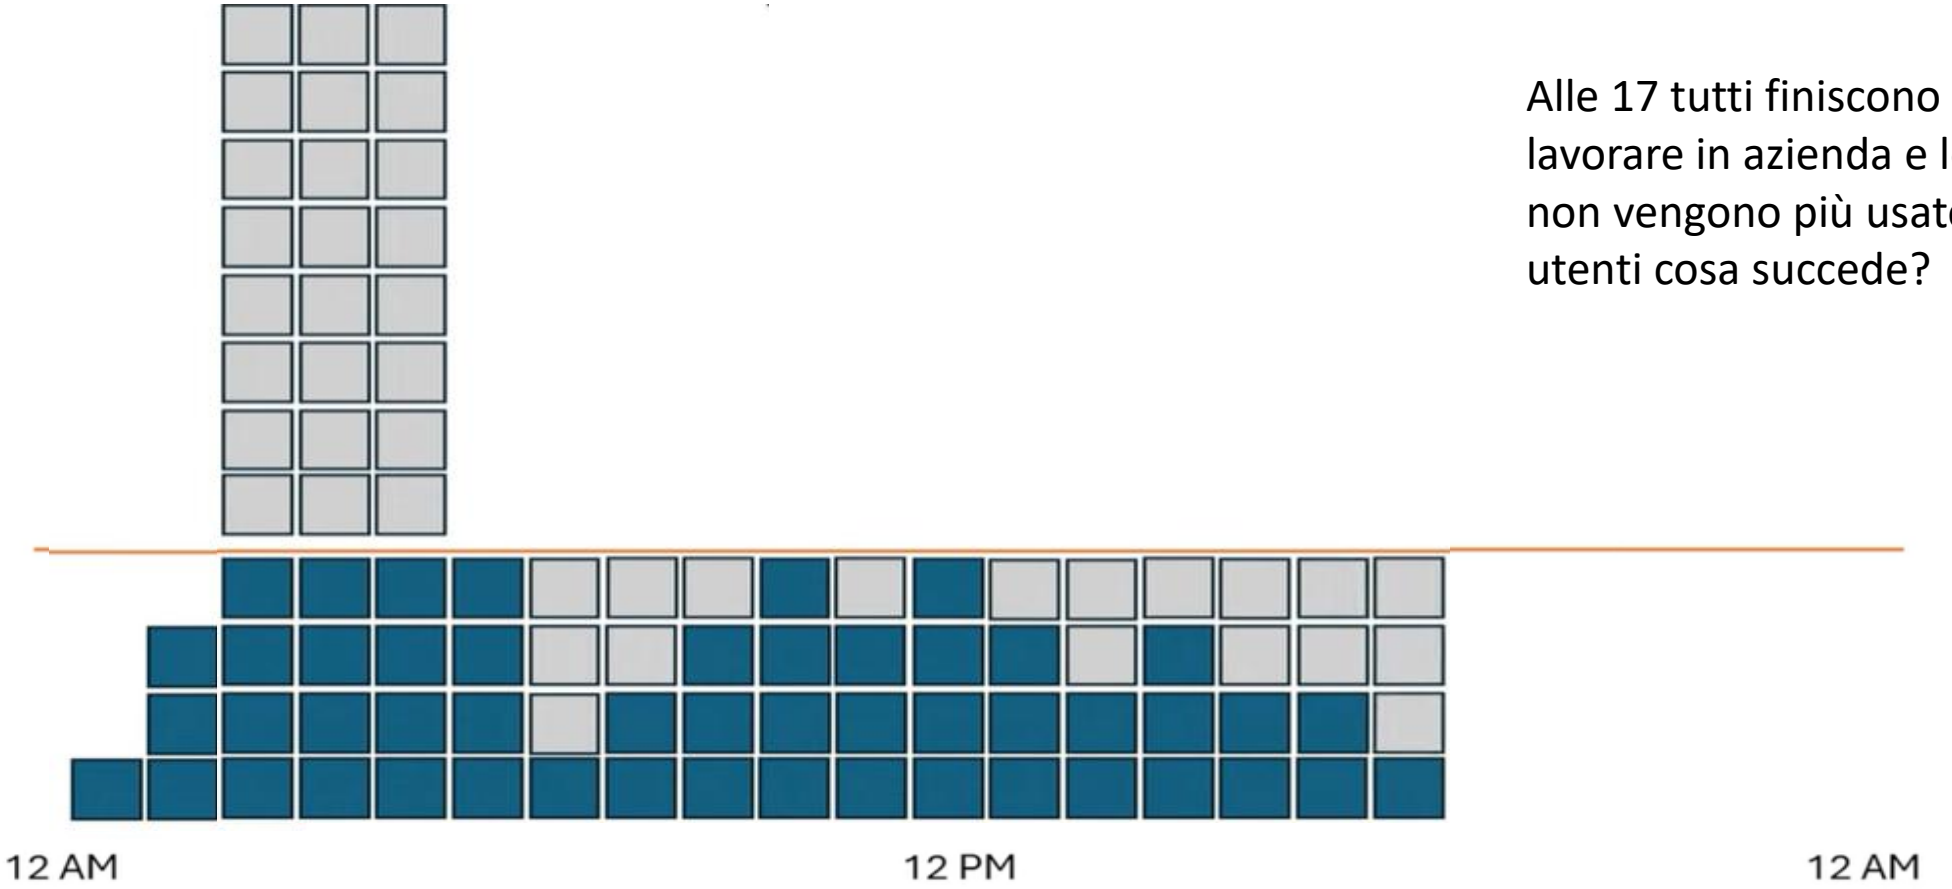

Alle 17 tutti finiscono di lavorare in azienda e le CU non vengono più usate dagli utenti cosa succede?

lo smoothing continua fino alle 00:00

Fino alla fine della giornata lo smoothing continua e ripiana il credito di CU maturato la mattina nel caricamento

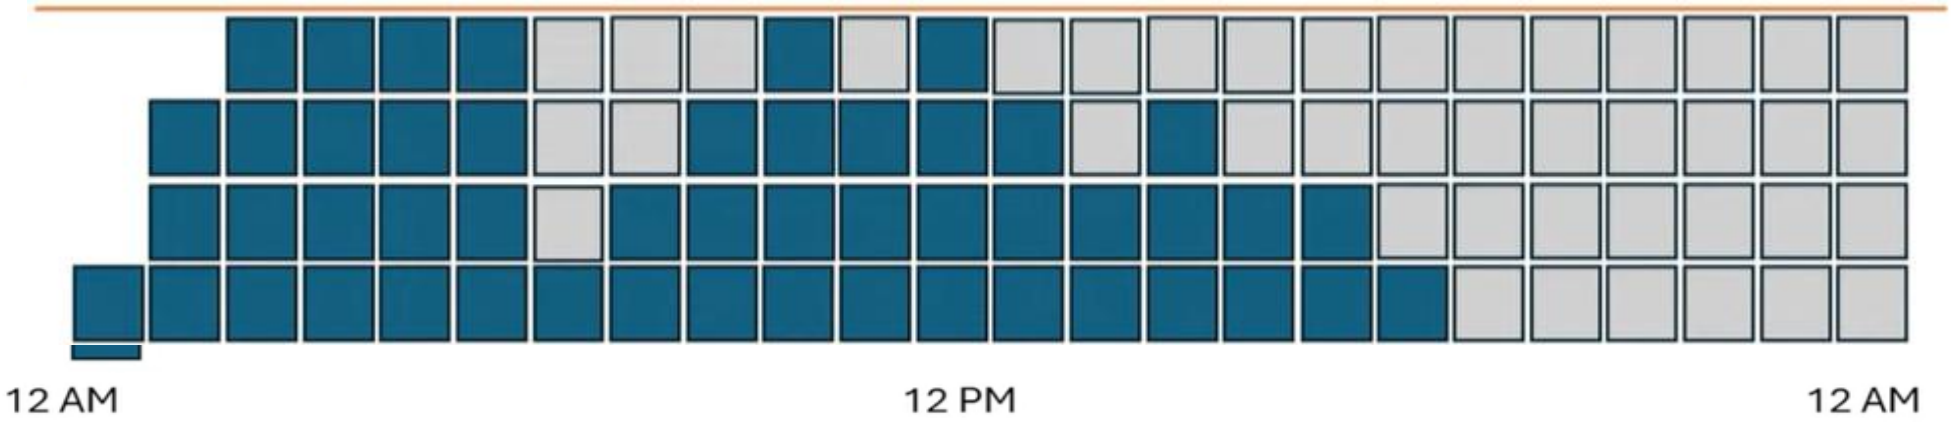

lo smoothing continua fino alle 00:00

Chi arriverà in questo momento come dei data scientist notturni troveranno l'errore «no CU disponibili»

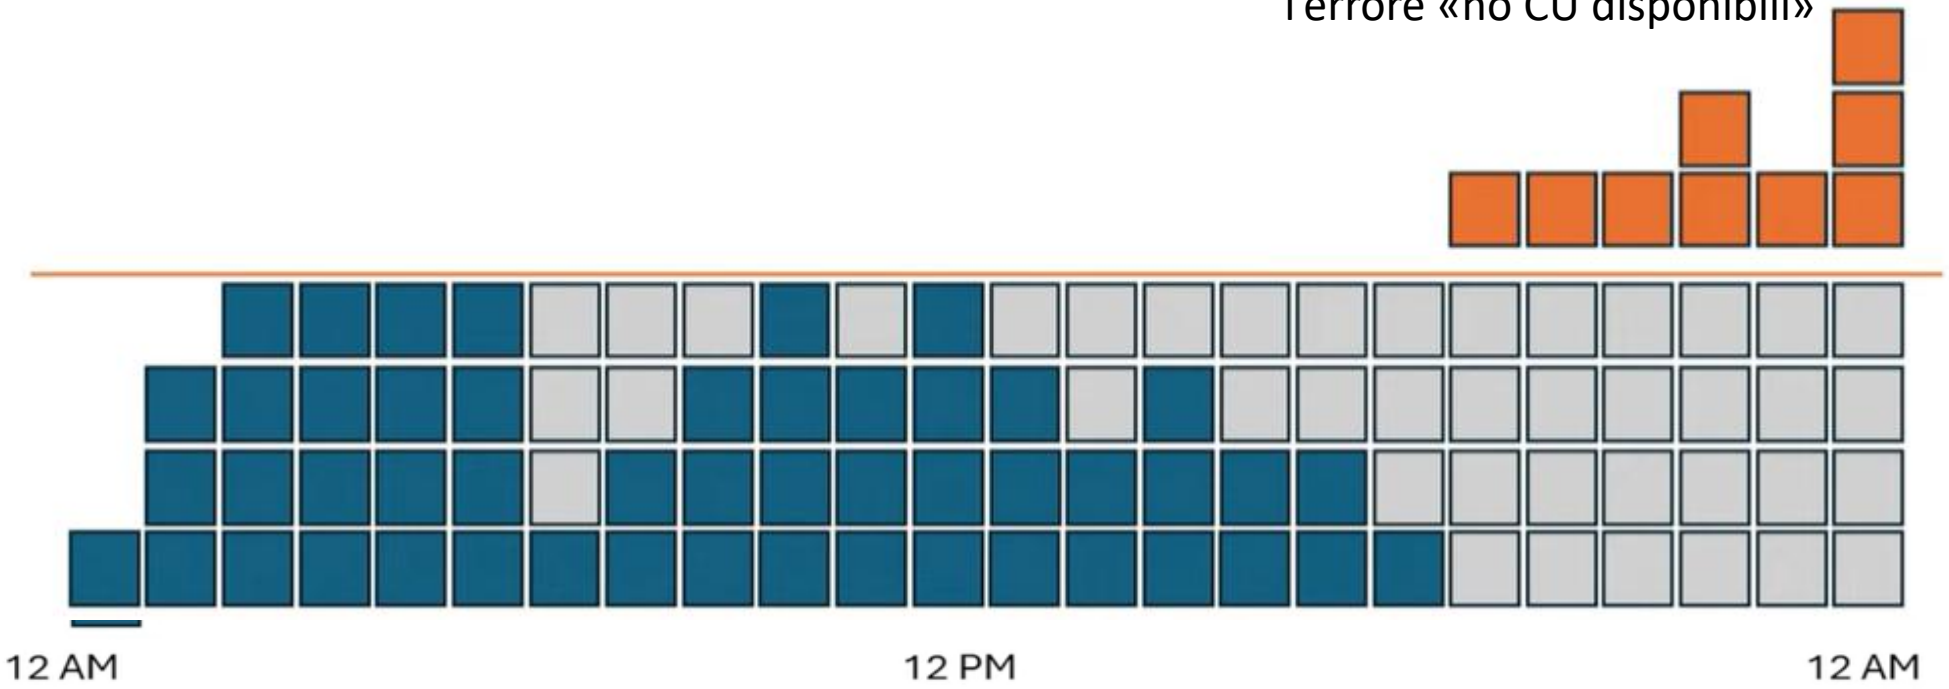

Non si può imbrogliare ☺

Per fare un esempio: se hai sfruttato il bursting per 1 ora e poi hai immediatamente messo in pausa la capacità di Fabric, ti verrà comunque addebitato al momento della pausa tutto il tempo CU "bursting" che è stato livellato nel futuro (ma che non ha potuto essere materializzato a causa della pausa della capacità):

Agenda

- Cosa sono le CU
- Allocazione Dinamica
  - Bursting
  - Smoothing
- Throttling
- Capacity Metric App
- Altri meccanismi di Resource Governator
- Guida alla pianificazione della capacità

Throttling (limitazioni) delle CU

- Le limitazioni sono applicate a livello di capacità

- Quando si verifica una limitazione? Quando ovviamente si utilizzano più CU rispetto alla SKU di capacità consentita

- Siamo nello scenario in cui le operazioni sono pesanti e richiedono più CU di quanto ne abbiamo e il sistema di Fabric le esegue comunque ma il calcolo viene distribuito in un periodo di tempo più lungo (smoothing)

Come entrano in gioco le limitazioni di CU

- Per mantenere la disponibilità delle risorse di elaborazione a livello generale ed evitare che un tenant superi la propria quota, la limitazione può essere applicata alle capacità che superano l'allocazione designata.

- Una capacità attiva la limitazione quando esaurisce le CU disponibili per la finestra temporale di 10 minuti successiva (determinate dallo smoothing).
  - Da questa condizione partono quattro tipi di limitazioni che vedremo nelle slide successive.

Fasi della limitazione (Throttling)

Policy	Consumo	Impatto
Overage protection	utilizzo <= 10 minuti	I processi possono consumare fino a 10 minuti di capacità futura senza subire limitazioni (throttling).
Interactive delay	10 minuti < utilizzo <= 60 minuti	I processi interattivi richiesti dall'utente vengono ritardati di 20 secondi al momento dell'invio.
Interactive rejection	60 minuti < utilizzo <= 24 ore	I processi interattivi richiesti dall'utente vengono rifiutati.
Background rejection	Utilizzo > 24 Ore	I job di background pianificati dall'utente vengono rifiutati e non eseguiti.

Demo simulata

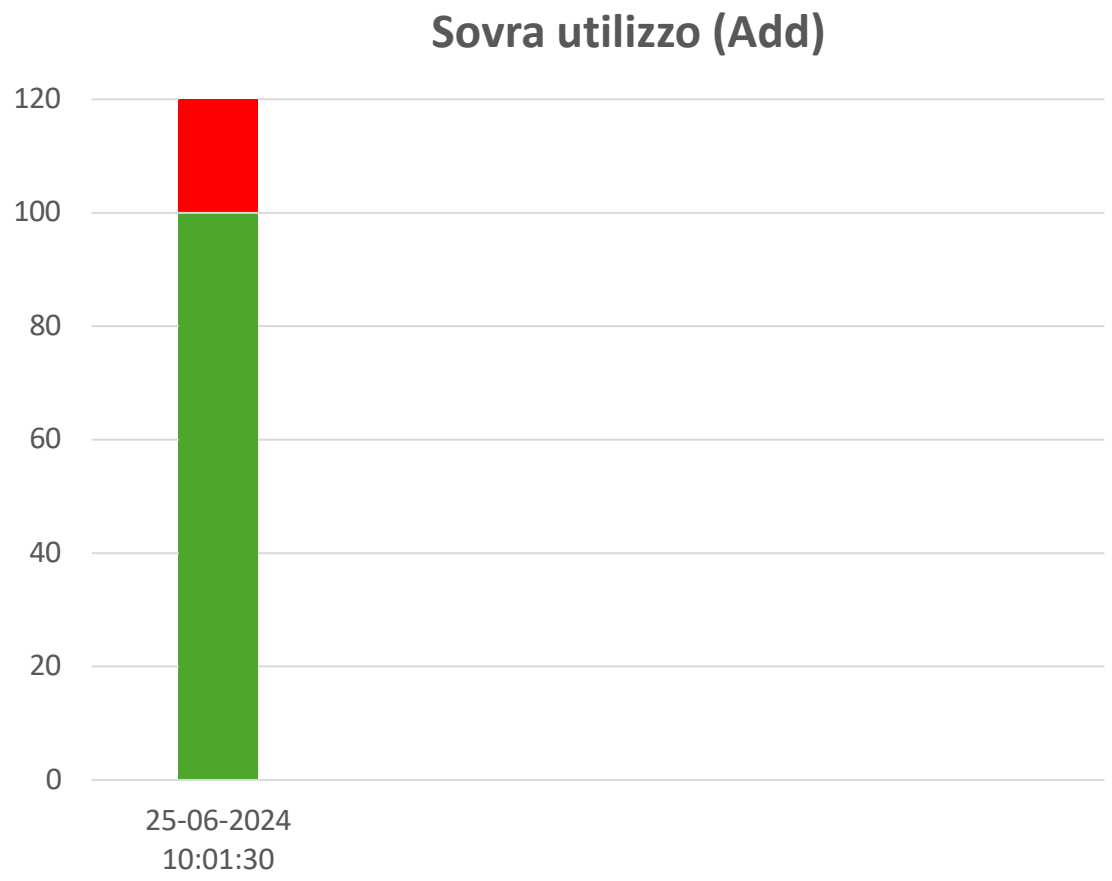

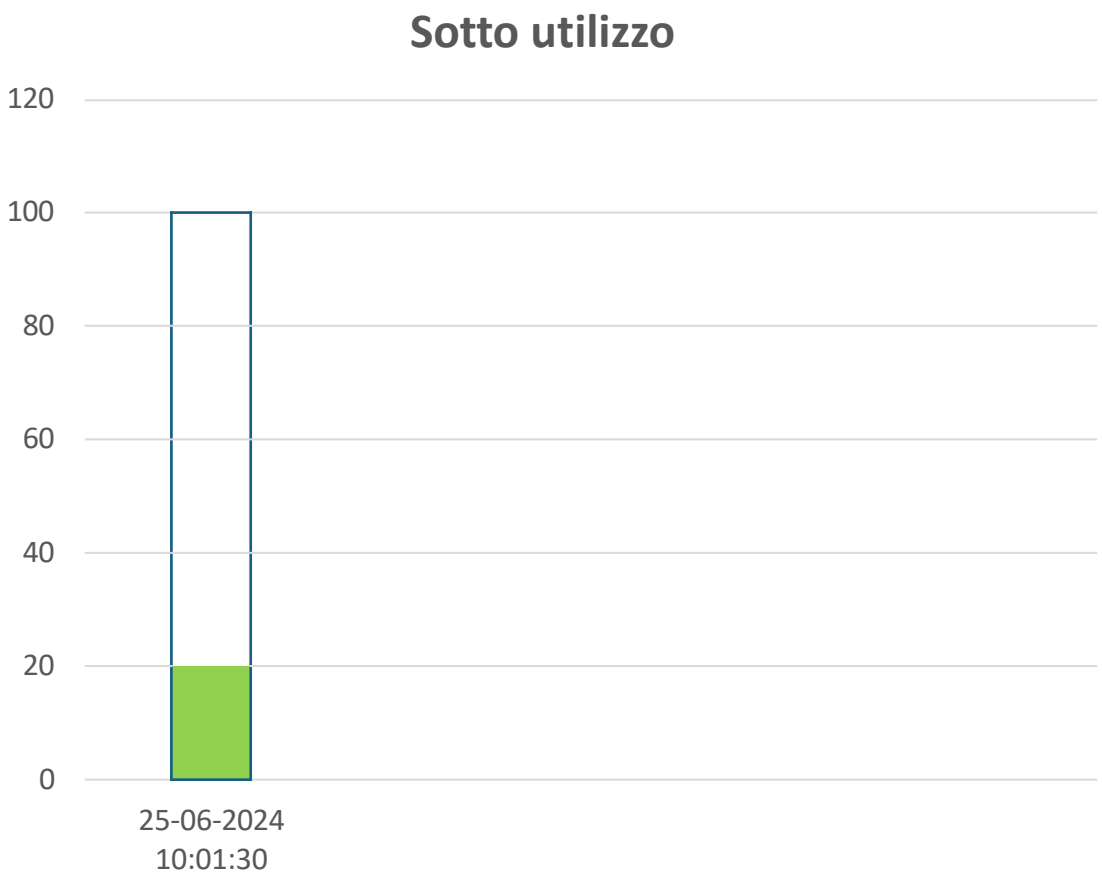

Demo simulata – overage protection

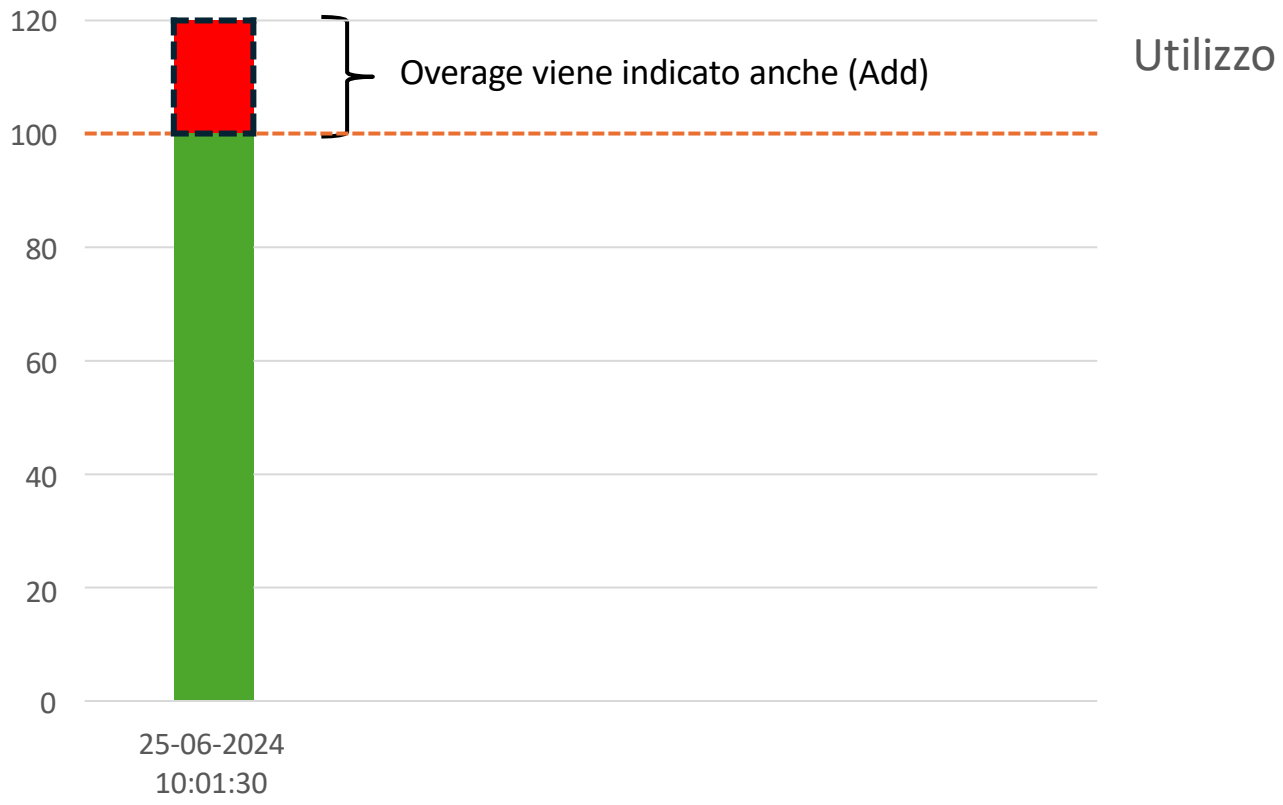

Demo simulata – overage protection

Sovra utilizzo <= 10 minuti

I processi possono consumare fino a 10 minuti di capacità futura senza subire limitazioni (throttling).

Tutto quello che va oltre il 10 minuti di carico extra SKU di CU si chiamano di riporto **Carryforward)**

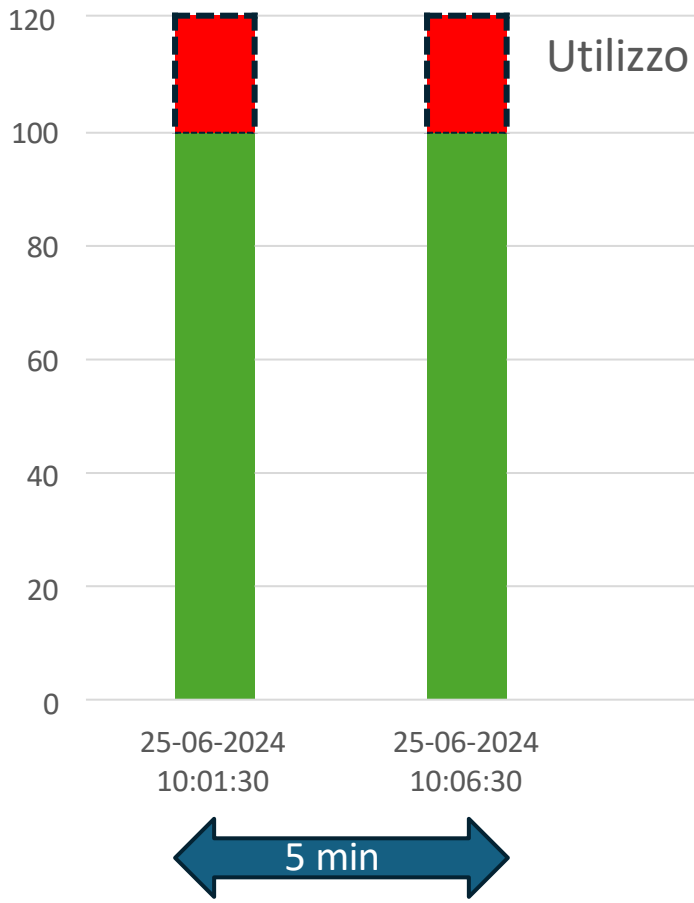

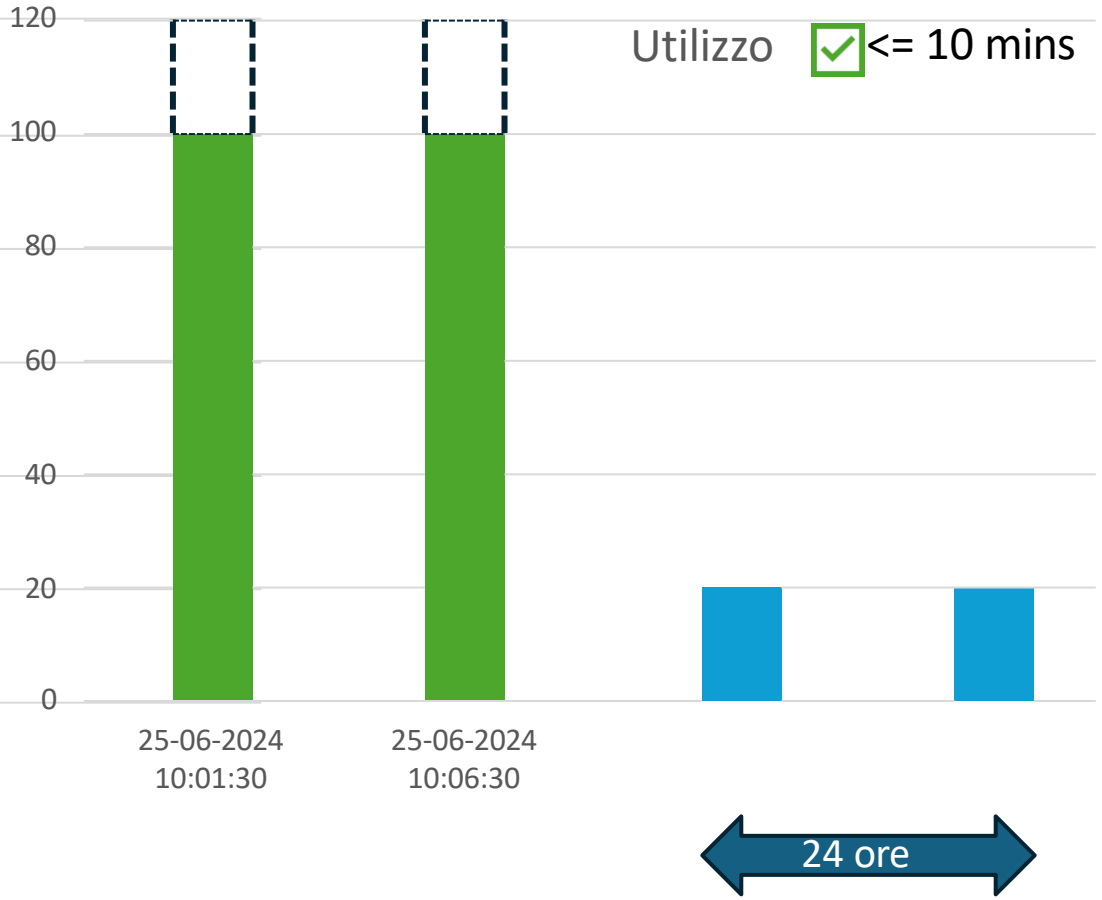

Demo simulata – interactive delay

10 minuti >utilizzo <= 60 minuti

I processi interattivi richiesti dall'utente vengono ritardati di 20 secondi al momento dell'invio.

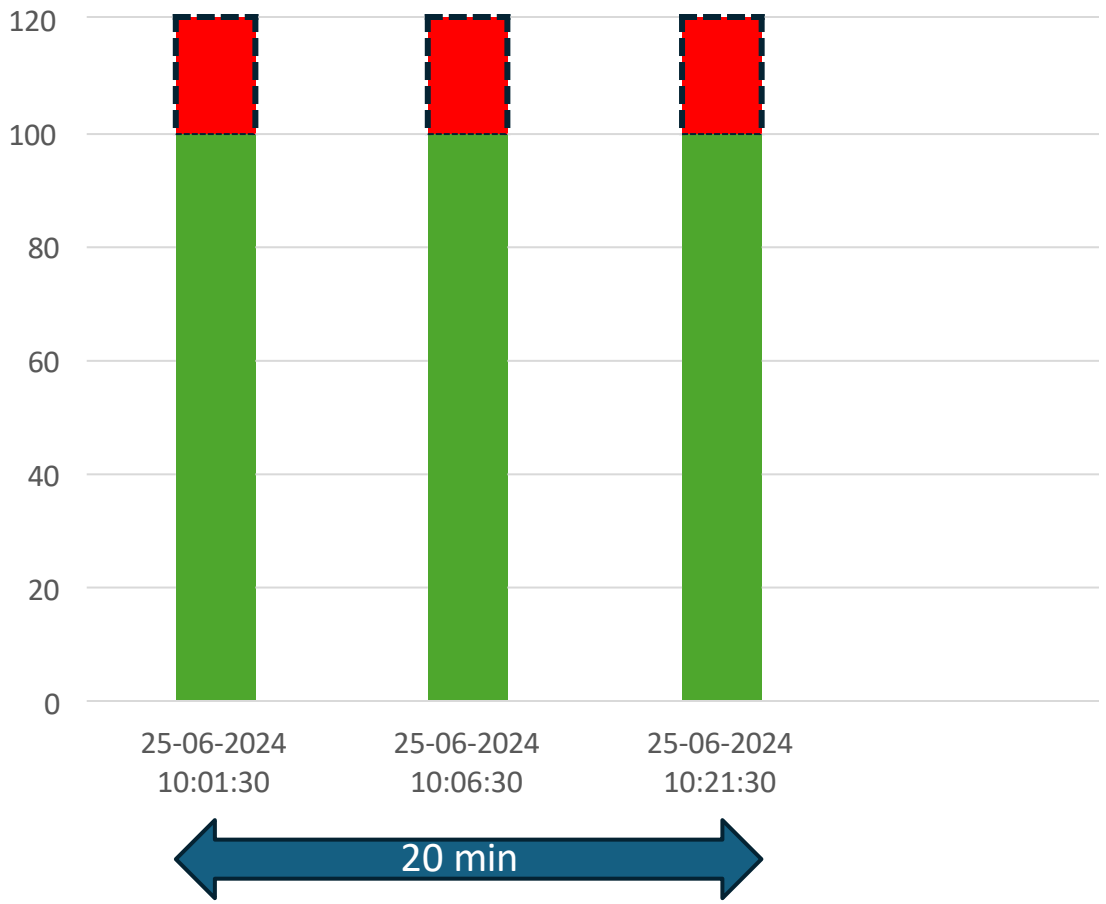

Utilizzo

- ☑ 10 min > consumo CU <= 60 min

Demo simulata – interactive rejection

60 minuti > utilizzo <= 24 ore

I processi interattivi richiesti dall'utente vengono rifiutati.

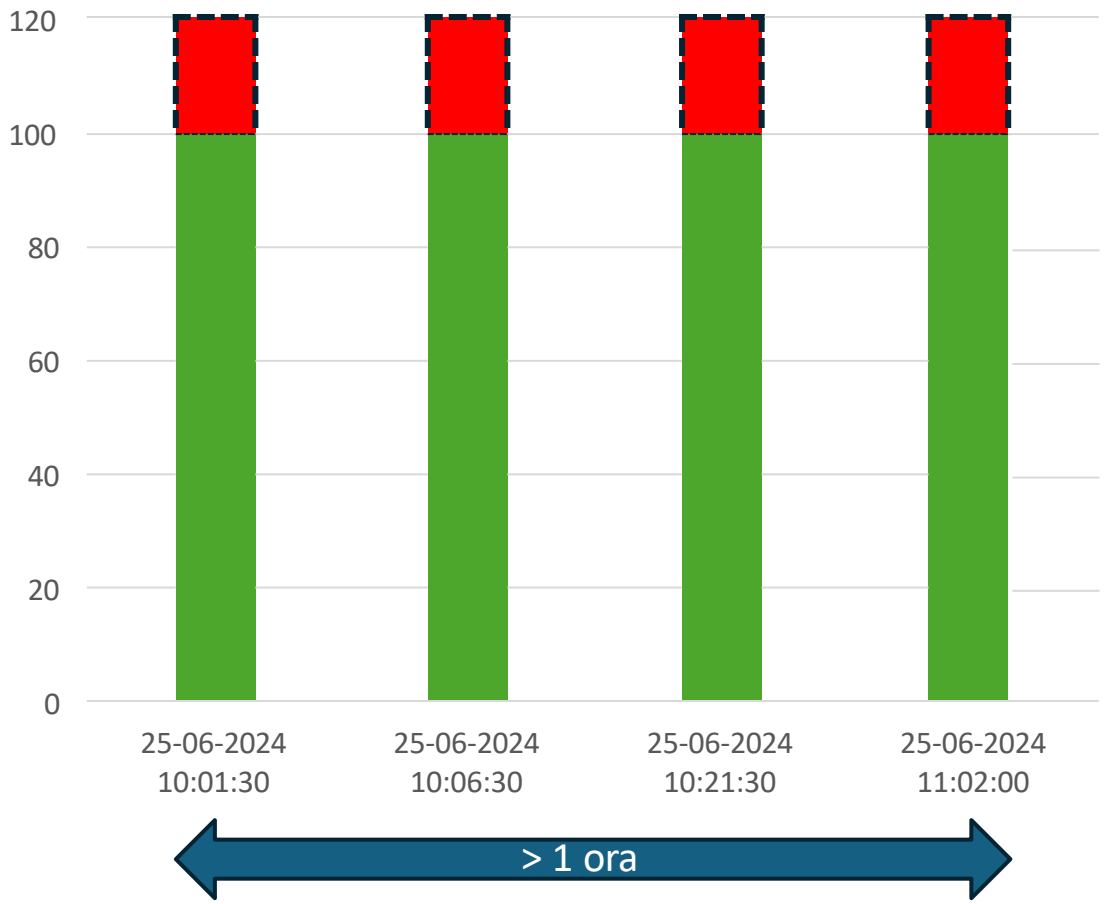

Utilizzo

- ☑ 60 min > utilizzo CU <= 24 ore

Demo simulata – Background Rejection

Utilizzo > 24 Ore

I job di background pianificati dall'utente vengono rifiutati e non eseguiti.

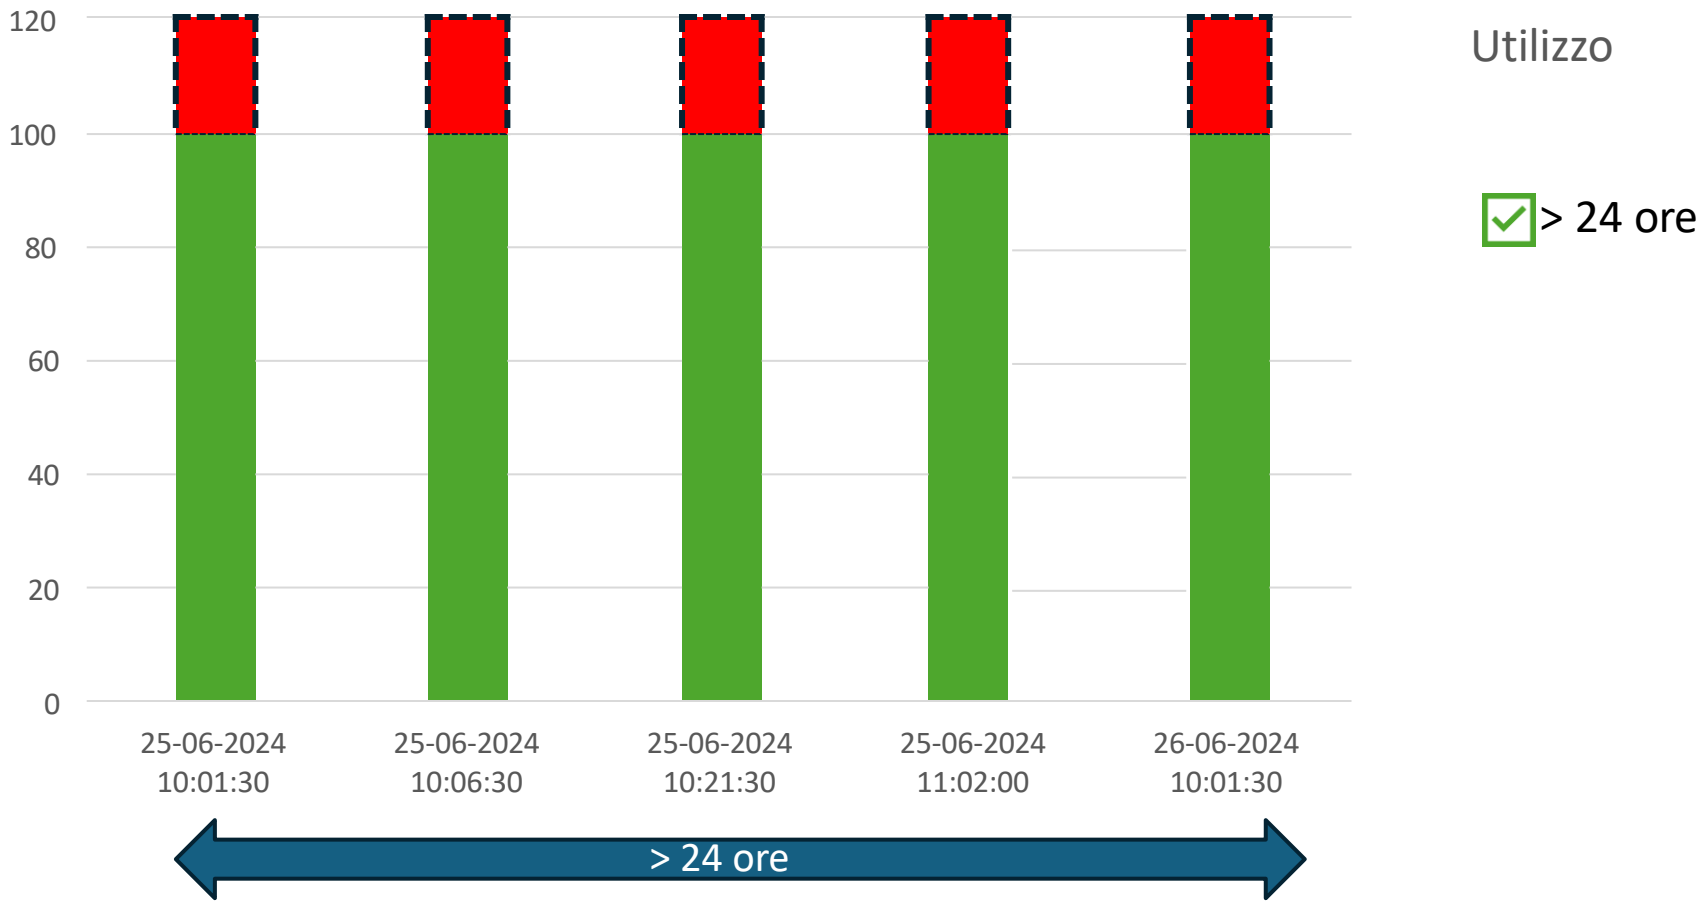

Recap

Scalable Compute

- **Capacity Unit (CUs)** metriche fondamentali per misurare/fornire la potenza di calcolo
- La dimensione dello SKU determina il numero di CU disponibili
- **Multiple workloads** possono utilizzare la stessa capacità contemporaneamente

Resizable, Pausable

- I piccoli SKU (F2) partono da meno di € 250 al mese
- **Ridimensiona** per aumentare **o diminuire** lo SKU in base alle tue esigenze di elaborazione
- Metti **in pausa e riprendi** la capacità – solo con l'opzione "PAY as you GO"

Self-Managing

- **Il bursting** consente ai processi di funzionare al massimo delle prestazioni.
- **Lo smoothing** riduce l'impatto dei picchi di elaborazione.

Throttling

- Le capacità offrono **built-in resource governance** quando c'è troppo utilizzo livellato (smoothing), si applica il **throttling**
- Built-in **overage protection** consente di consumare 10 minuti di risorse CU future prima che inizi la limitazione

Agenda

- Cosa sono le CU
- Allocazione Dinamica
  - Bursting
  - Smoothing
- Throttling
- Capacity Metric App
- Altri meccanismi di Resource Governator
- Guida alla pianificazione della

Capacity Metrics App

- La Microsoft Fabric Capacity Metrics App **serve a monitorare le capacità di Microsoft Fabric;**

- Aiuta a monitorare la capacità e prendere decisioni su come usare le risorse

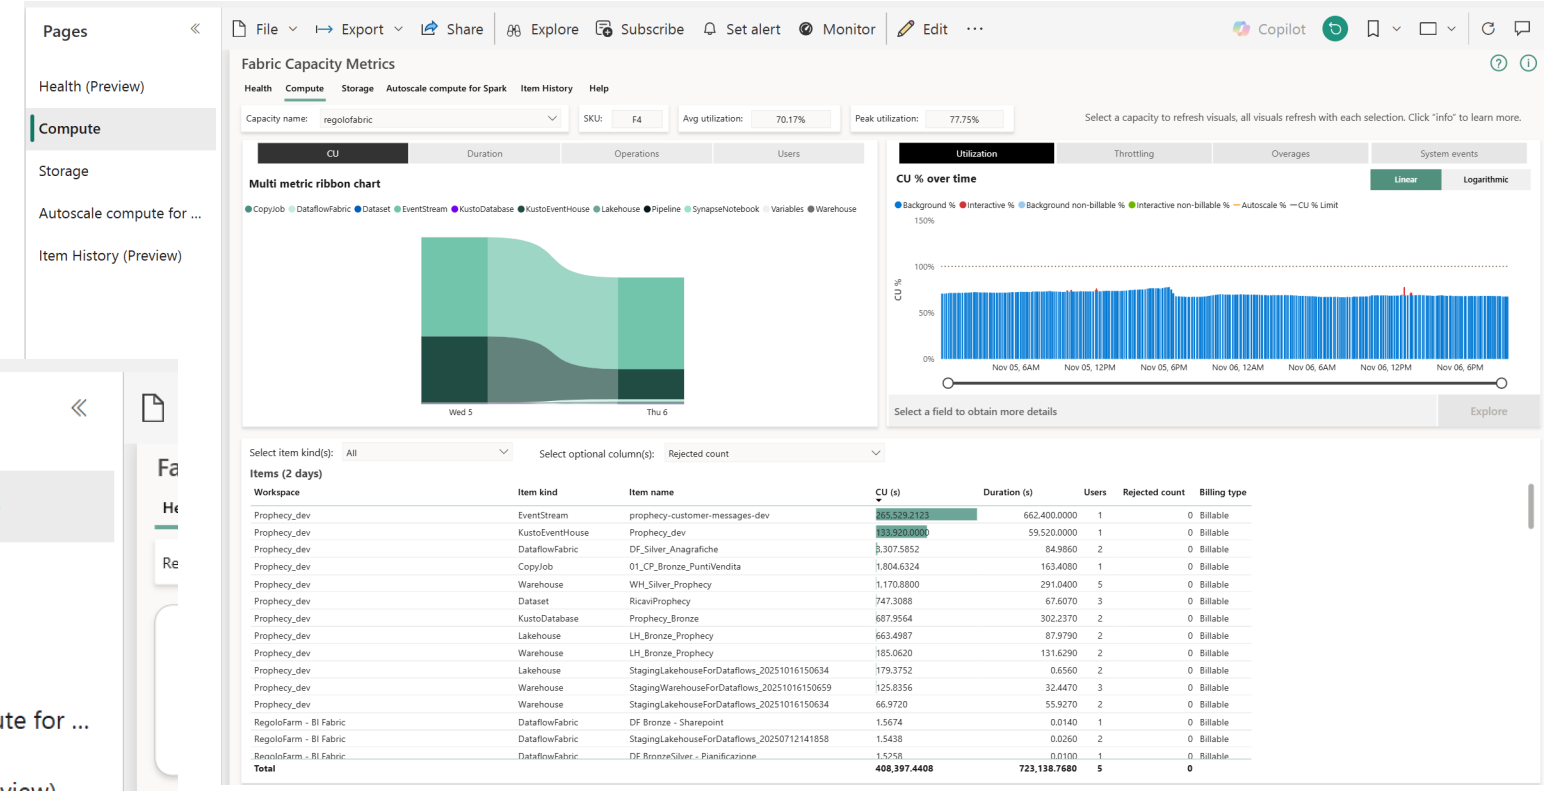

Installazione Capacity Metrics App

- Devi essere un Amministratore della capacità per installare e vedere la Capacity Metrics App

- Install Capacity metrics app Install the Microsoft Fabric capacity metrics app - Microsoft Fabric | Microsoft Learn

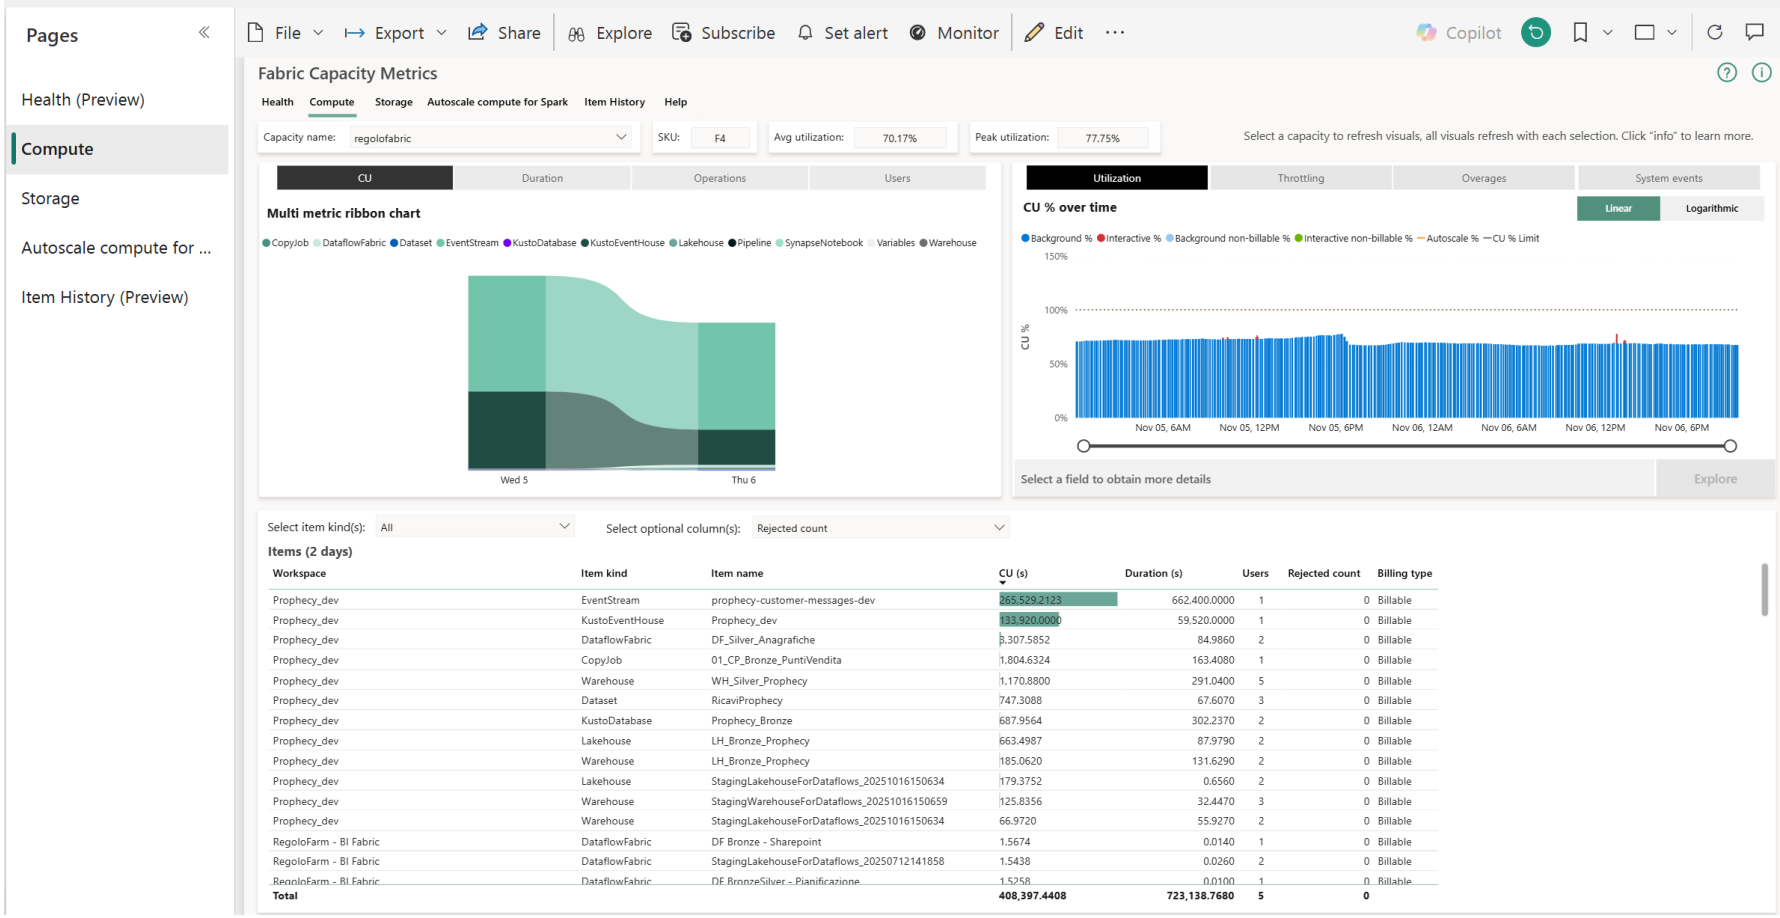

Aree di suddivisione dell'App

Ci sono 5 aree di monitoraggio

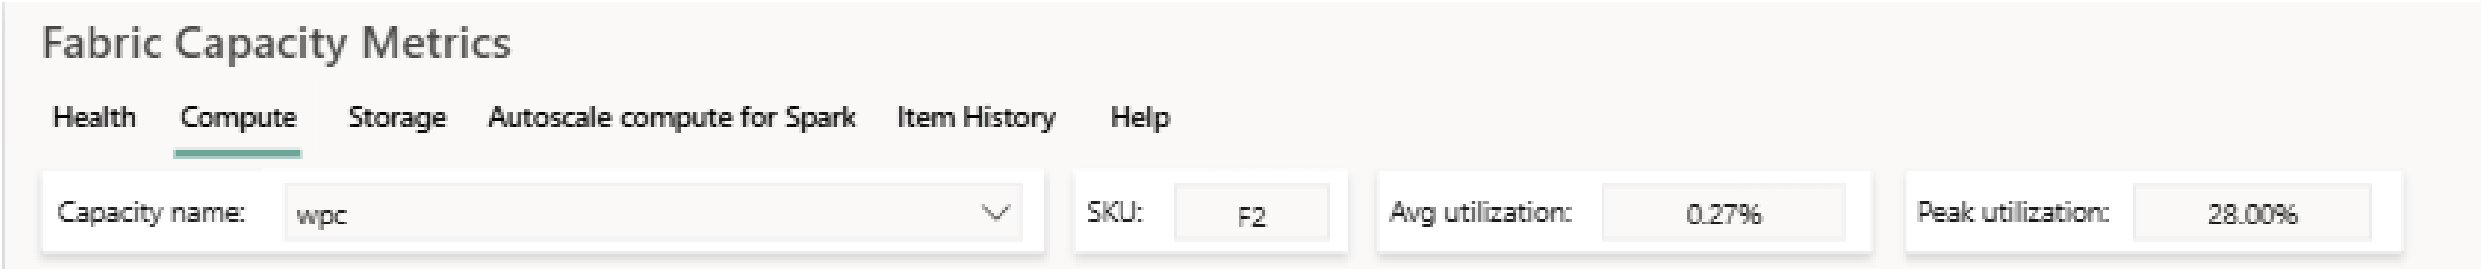

Health

In Public Preview

- Fornisce un unico pannello di controllo per valutare lo **stato di tutte le capacità in una specifica regione**
- I clienti possono visualizzare attributi come: "Utilizzo medio", "Livello/percentuale di limitazione", "SKU", "Regione", ecc., tutti a colpo d'occhio
- **Se necessario, i clienti possono analizzare in dettaglio il consumo di elaborazione e storage per capacità**

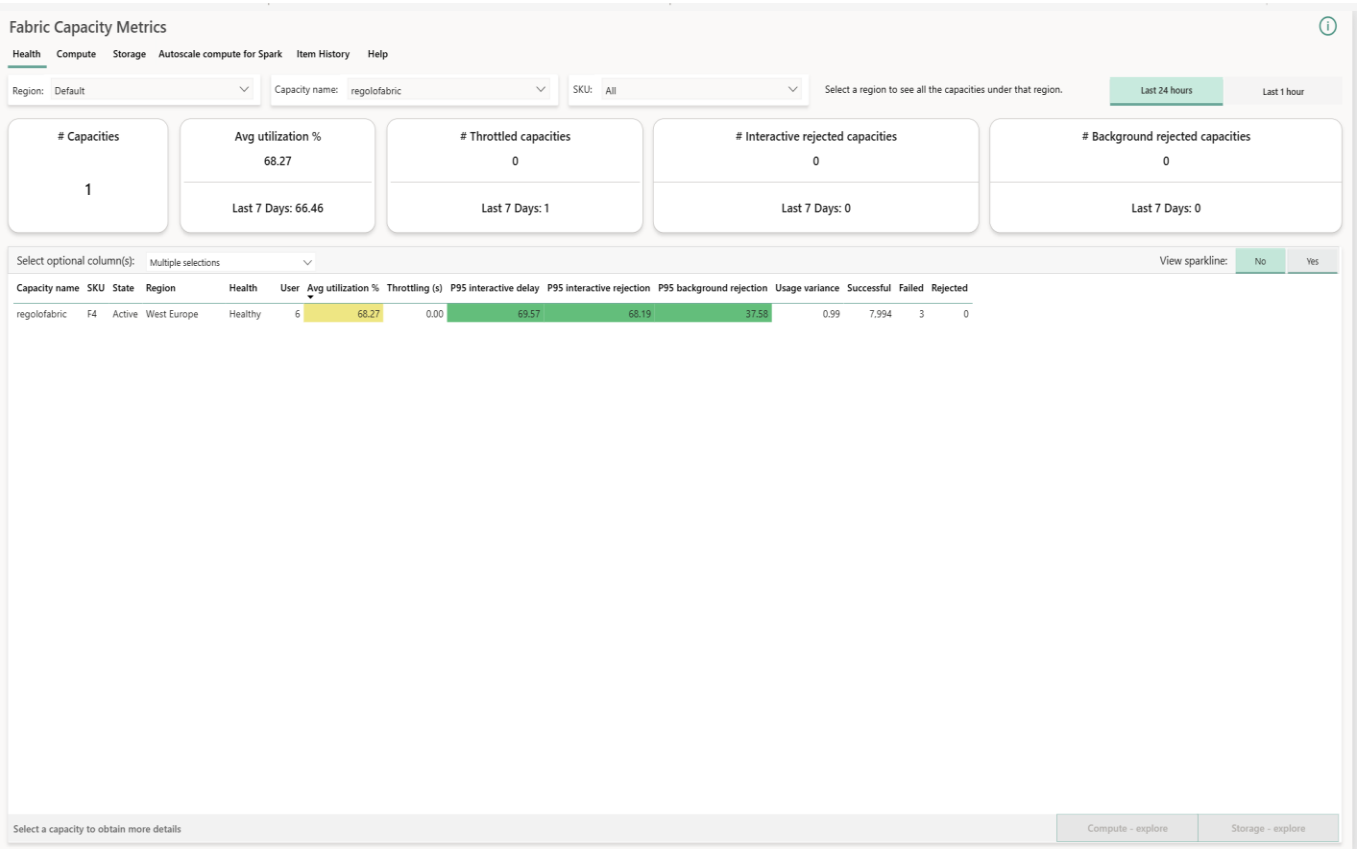

Compute

È suddiviso nelle tre visualizzazioni elencate nelle sezioni seguenti.
Le prime due visualizzazioni includono:

- **un ribbon chart**
- **un bar and line chart**

L'ultima visualizzazione, in basso, è una **tabella a matrice**

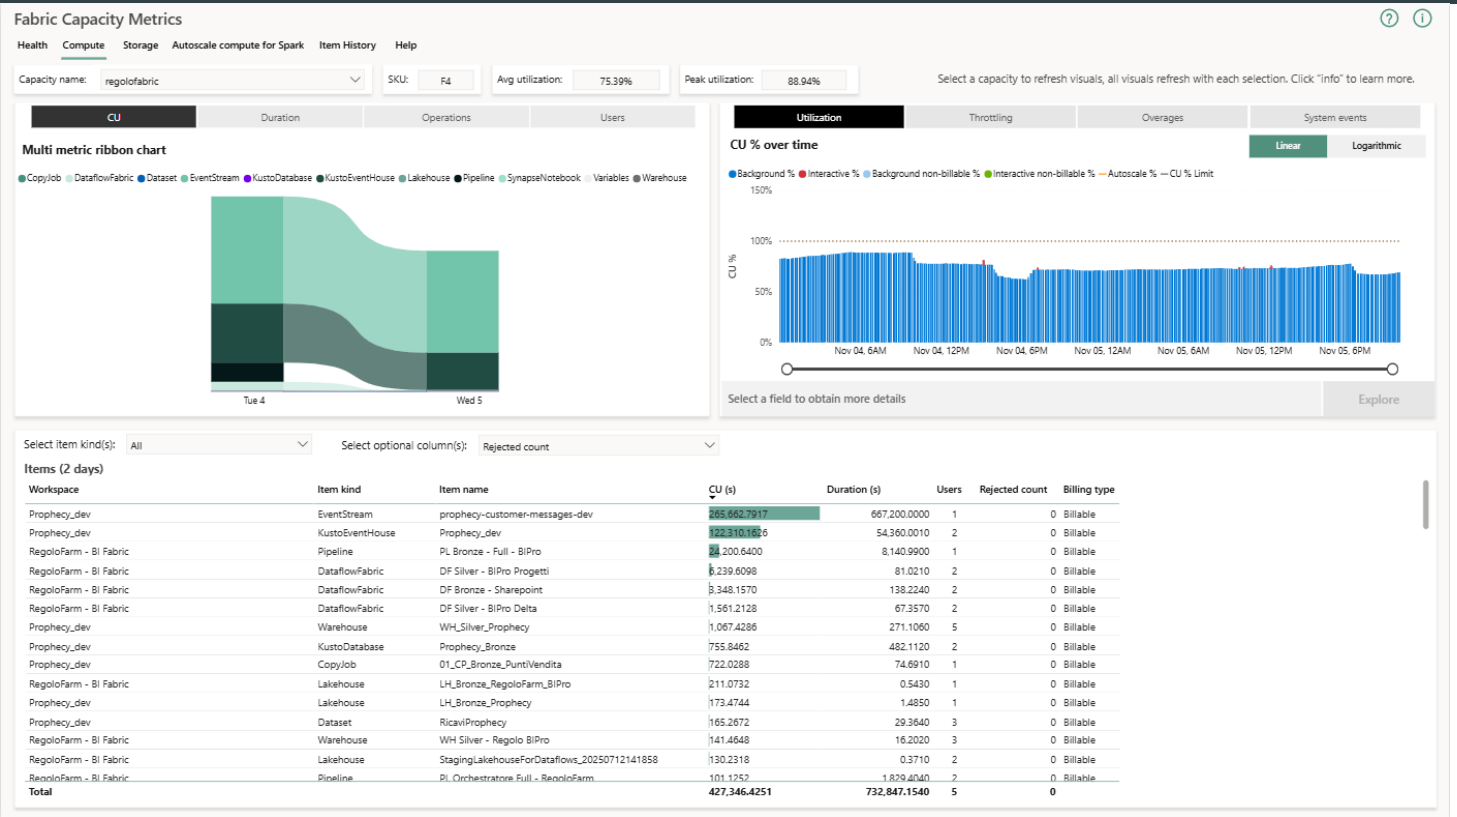

Workspace	Item kind	Item name	CU (s)	Duration (s)	Users	Rejected count	Billing type
Prophecy_dev	EventStream	prophecy-customer-messages-dev	265,662.7917	667,200.0000	1	0	Billable
Prophecy_dev	KustoEventHouse	Prophecy_dev	122,310.1626	54,360.0010	2	0	Billable
RegoloFarm - BI Fabric	Pipeline	PL Bronze - Full - BIPro	24,200.6400	8,140.9900	1	0	Billable
RegoloFarm - BI Fabric	DataflowFabric	DF Silver - BIPro Progetti	6,239.6098	81.0210	2	0	Billable
RegoloFarm - BI Fabric	DataflowFabric	DF Bronze - Sharepoint	3,348.1570	138.2240	2	0	Billable
RegoloFarm - BI Fabric	DataflowFabric	DF Silver - BIPro Delta	1,561.2128	67.3570	2	0	Billable
Prophecy_dev	Warehouse	WH_Silver_Prophecy	1,067.4286	271.1060	5	0	Billable
Prophecy_dev	KustoDatabase	Prophecy_Bronze	755.8462	482.1120	2	0	Billable
Prophecy_dev	CopyJob	01_CP_Bronze_PuntiVendita	722.0288	74.6910	1	0	Billable
RegoloFarm - BI Fabric	Lakehouse	LH_Bronze_RegoloFarm_BIPro	211.0732	0.5430	1	0	Billable
Prophecy_dev	Lakehouse	LH_Bronze_Prophecy	173.4744	1.4850	1	0	Billable
Prophecy_dev	Dataset	RicaviProphecy	165.2672	29.3640	3	0	Billable
RegoloFarm - BI Fabric	Warehouse	WH Silver - Regolo BIPro	141.4648	16.2020	3	0	Billable
RegoloFarm - BI Fabric	Lakehouse	StagingLakehouseForDataflows_20250712141858	130.2318	0.3710	2	0	Billable
RegoloFarm - BI Fabric	Pipeline	PL Orchestratore Full - RegoloFarm	101.1252	1,829.4040	2	0	Billable
Total			**427,346.4251**	**732,847.1540**	**5**	**0**	

Compute

Per vedere le metriche selezionare la capacità

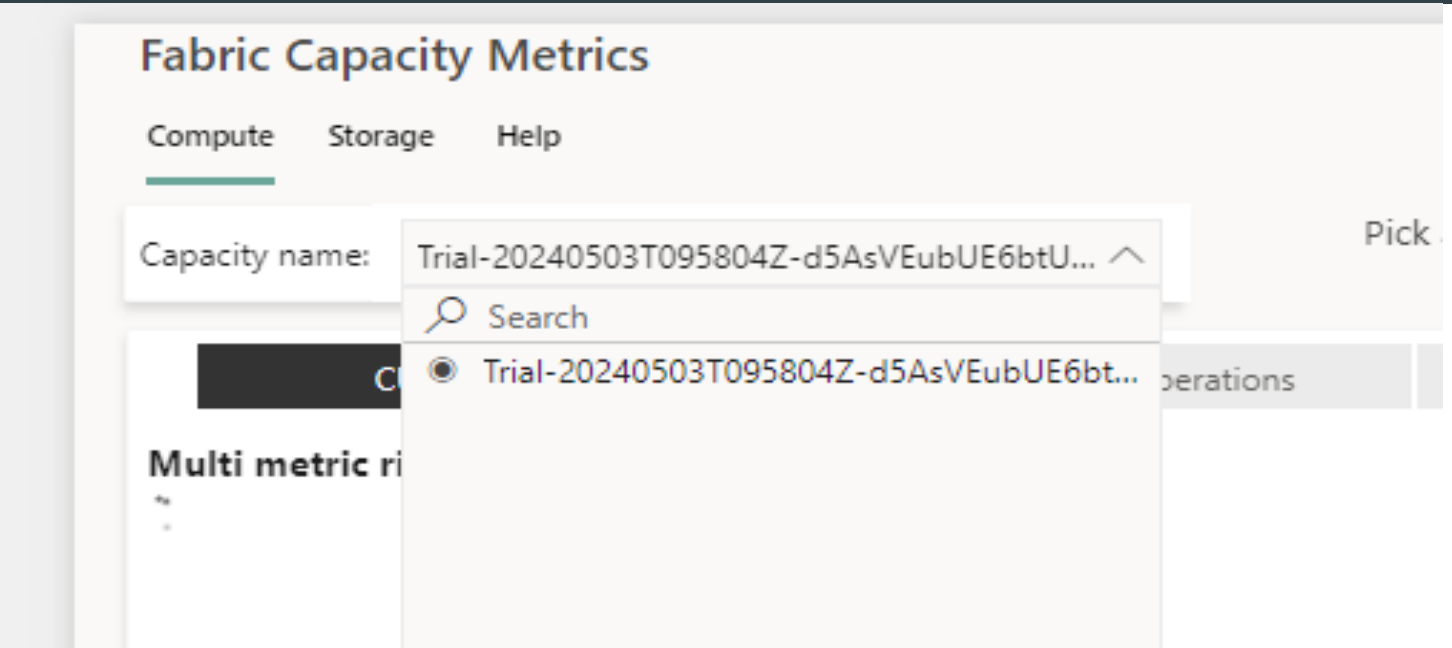

Compute - ribbon chart

Il ribbon chart multi-metrica **fornisce una visualizzazione oraria dell'utilizzo della capacità.**

Per identificare i **pattern giornalieri**, è possibile effettuare un **drill-down fino a un giorno specifico**.

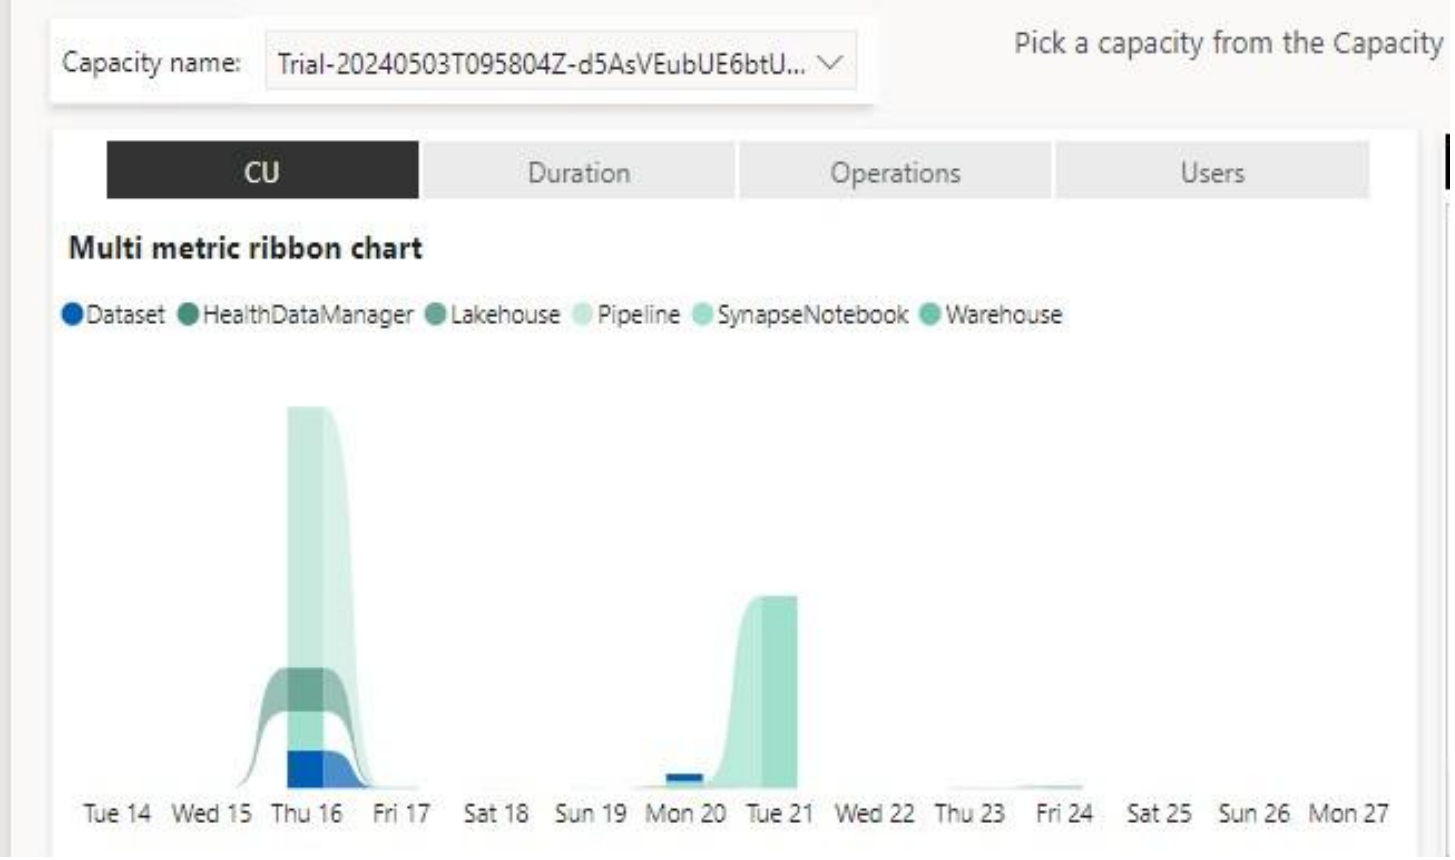

Compute - ribbon chart

Il grafico mostra i seguenti quattro valori. **Nelle ultime due settimane, per ciascun elemento, vedrai i risultati principali per questi valori**:

CU – Capacity Units (CU): tempo di elaborazione in secondi

Durata: tempo di elaborazione in secondi

Operazioni: numero di operazioni eseguite

Utenti: numero di utenti che hanno effettuato operazioni

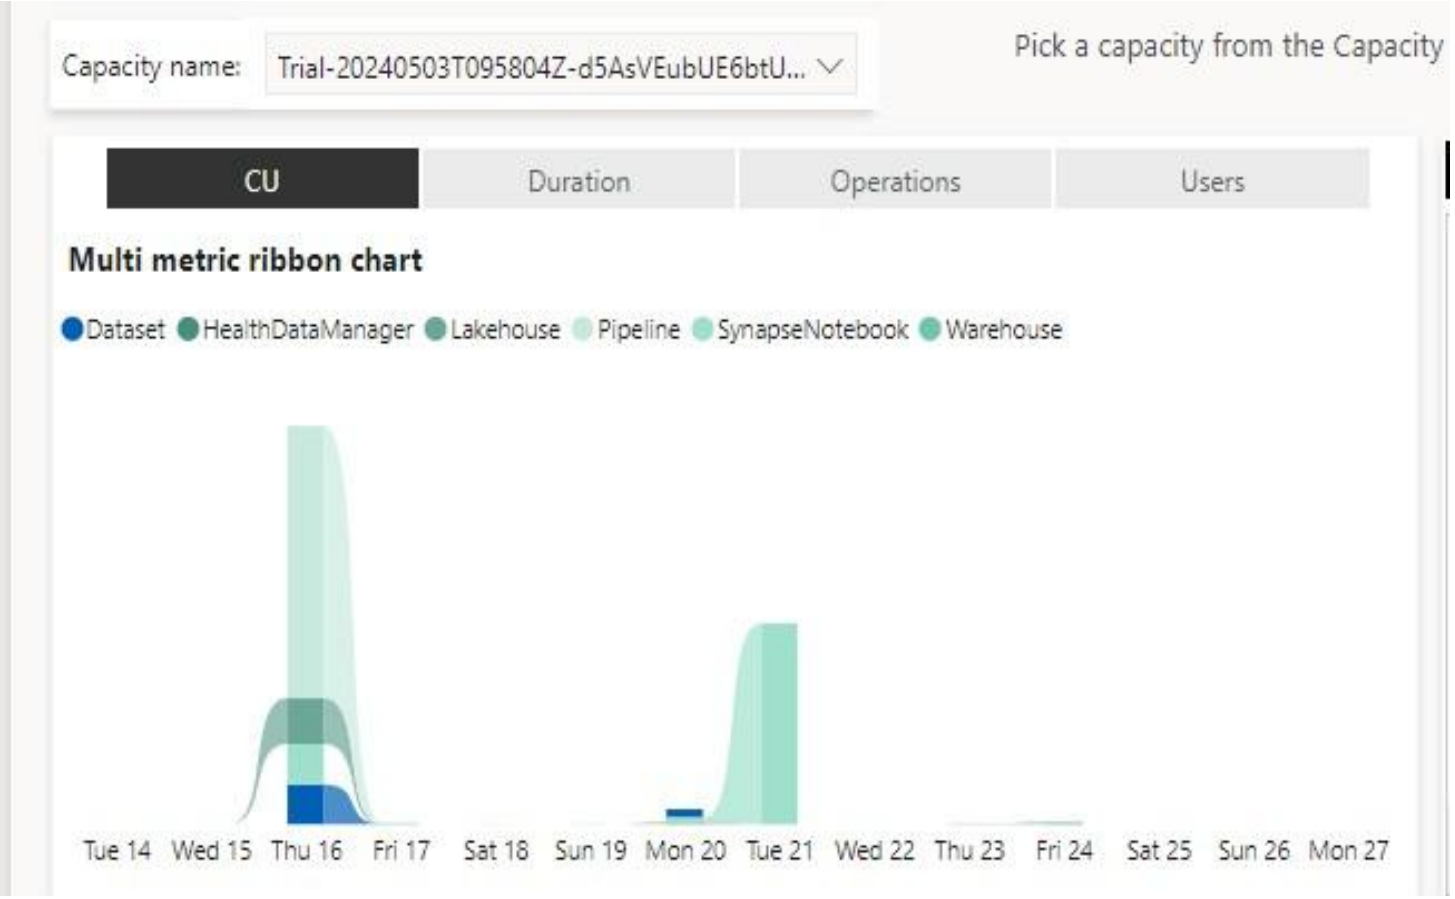

Compute - grafico a barre

Usa le schede nell'angolo in alto a destra della visualizzazione per cambiare il modo in cui viene mostrato il grafico.

- **Lineare** – Mostra le informazioni utilizzando una scala lineare che parte dallo 0%.
- **Logaritmica** – Mostra le informazioni utilizzando una scala logaritmica che dipende dal consumo delle tue CU.

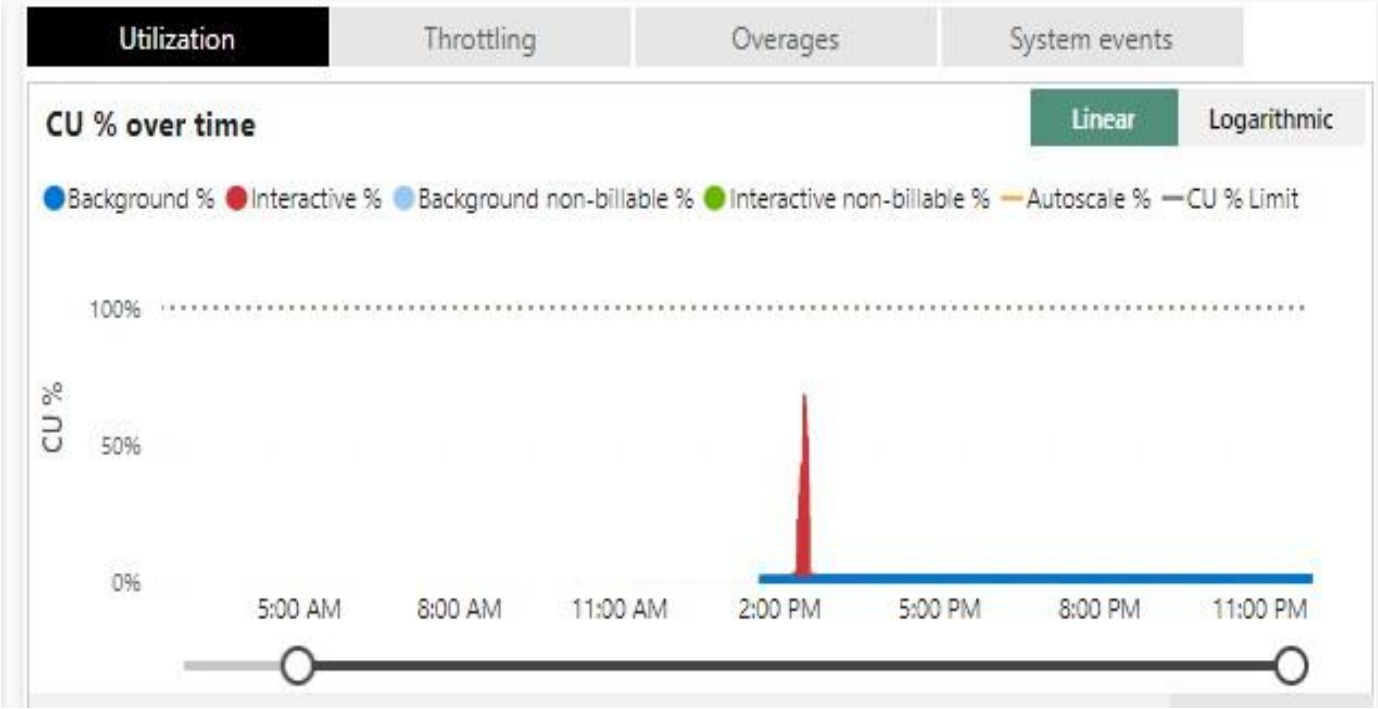

Compute - grafico a barre - utilizzo

Visualizza l'utilizzo di CU nel tempo.

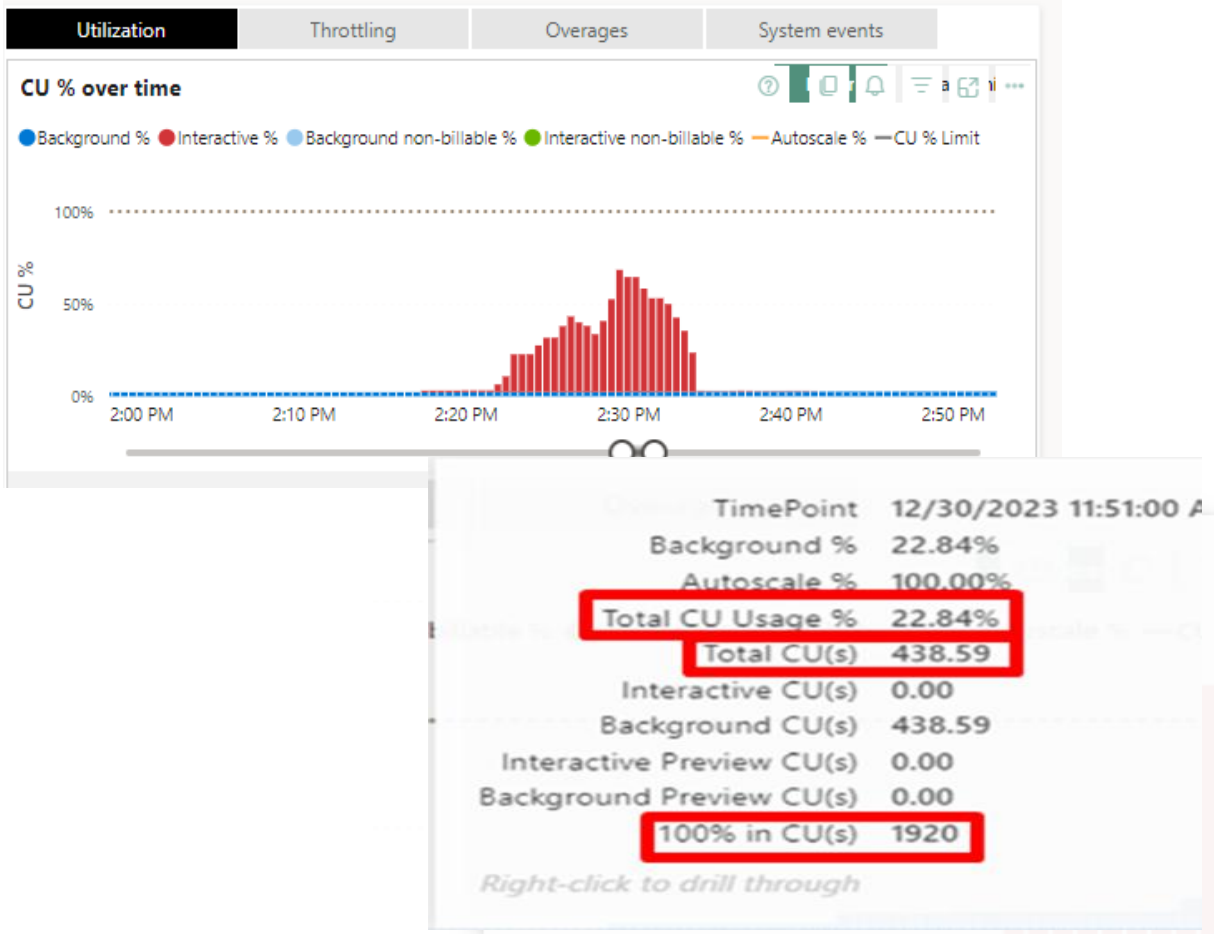

Compute - grafico a barre - Throttling

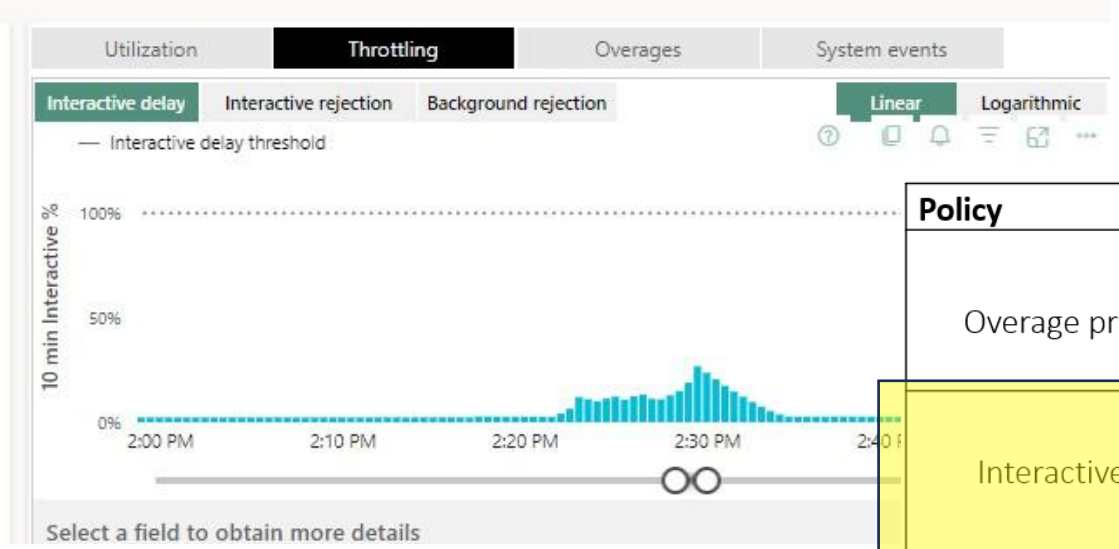

Visualizza il ritardo e il rifiuto nel tempo.

Policy	Consumo	Impatto
Overage protection	utilizzo <= 10 minuti	I processi possono consumare fino a 10 minuti di capacità futura senza subire limitazioni (throttling).
Interactive delay	10 minuti < utilizzo <= 60 minuti	I processi interattivi richiesti dall'utente vengono ritardati di 20 secondi al momento dell'invio.
Interactive rejection	60 minuti < utilizzo <= 24 ore	I processi interattivi richiesti dall'utente vengono rifiutati.
Background rejection	Utilizzo > 24 Ore	I job di background pianificati dall'utente vengono rifiutati e non eseguiti.

Compute - grafico a barre - Overages

- Quando le operazioni utilizzano una capacità maggiore a quella definita dallo SKU in un singolo momento, viene calcolato un *eccesso* (***Add***).

- Se ci sono eccessi che superano la finestra di limitazione consentita di 10 minuti, diventano CU *di riporto*(**Carryforward**) .

- Le CU *riportate* vengono applicate a ogni punto temporale successivo. Se un punto temporale non è pieno, le CU non utilizzate riducono la quantità di CU *riportate* . (***Burndown***).

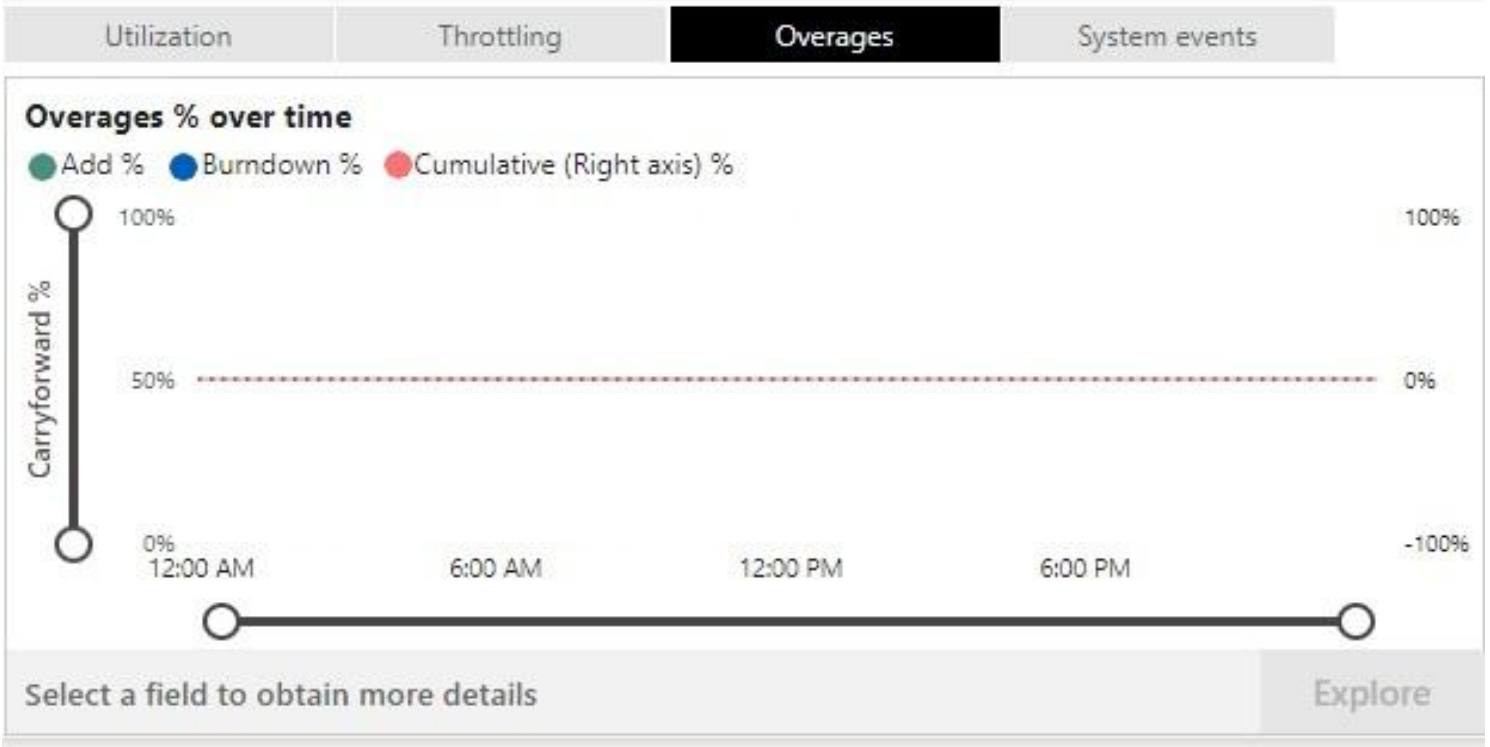

Esempio di Add

alle 12:00:00, l'utilizzo era al 99%, confermato dall'utilizzo di CU pari a 1900, appena al di sotto del massimo di 1920 per il nostro F64, che equivale al 99%. L'utilizzo ha continuato a crescere; nel ciclo di valutazione successivo alle 12:00:30, ha raggiunto il 109%, ovvero 2100 CU.

utilizzo eccessivo che si ripercuote sul ciclo di valutazione successivo, con un conseguente superamento di 180 CU (2100–1920), pari al 9,38% dei CU della capacità.

Nel ciclo successivo, vengono aggiunti altri 580 CU all'importo cumulativo dei cicli precedenti (180 + 580 = 760).

Continueremo ad aggiungere al totale finché l'utilizzo rimarrà **superiore al 100%.**

Time	Usage %	CU (s) usage	Add	Cumulative (carryforward)	Burndown
12:00:00 PM	99%	1900	0	0	0
12:00:30 PM	109%	2100	180	0	0
12:01:00 PM	130%	2500	580	180	0
12:01:30 PM	141%	2700	780	760	0
12:02:00 PM	161%	3100	1180	1540	0

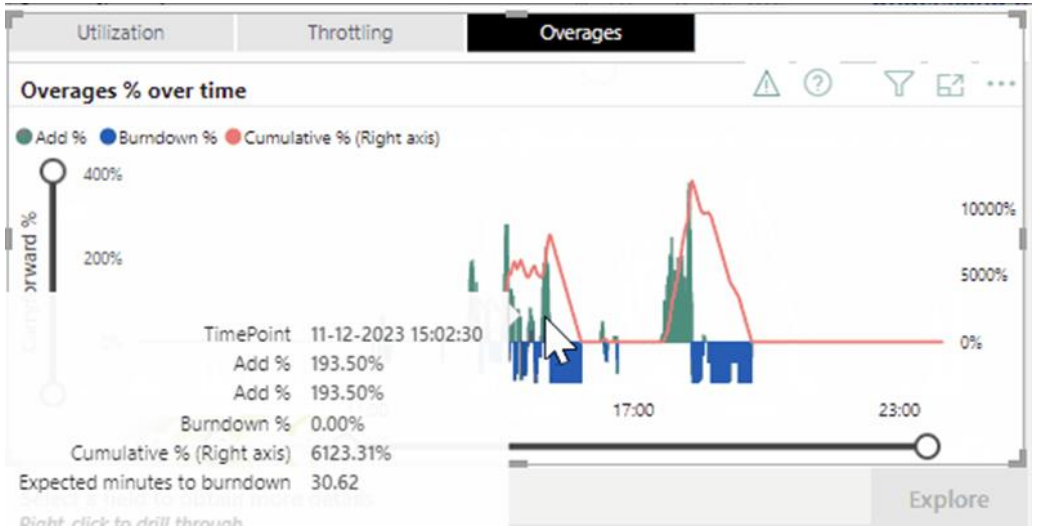

Esempio di burndown

Alle 12:02:30, la capacità scende sotto il 100%, lasciando inutilizzato l'11%, ovvero 220 CU (burndown) della capacità (1920–1700 = 220 CU). Questa capacità inutilizzata verrà utilizzata nel ciclo successivo per **bruciare** il debito cumulativo. Come si può vedere, alle 12:03:00, il debito cumulativo è sceso da 2720 a 2500.

- **linea rossa (cumulativa)** mostra l'eccedenza totale.
- **le linee blu e verde**, che indicano se stiamo aggiungendo eccedenza o bruciando il debito. È evidente che il burndown si verifica solo quando non viene aggiunta eccedenza (solo quando l'utilizzo è inferiore al 100%.)

Time	Usage %	CU (usage)	Add	Cumulative (CarryForward)	Burndown
12:02:00 PM	161%	3100	1180	1540	0
12:02:30 PM	**89%**	**1700**	**0**	**2720**	**220**
12:03:00 PM	78%	1500	0	2500	420
12:03:30 PM	63%	1200	0	2080	720

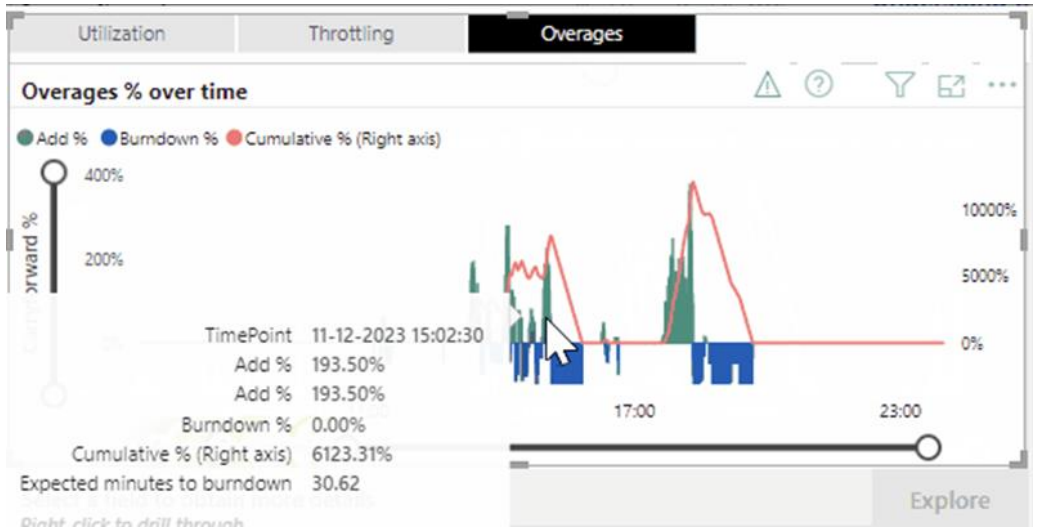

Compute - grafico a barre - System Events

Visualizza gli eventi relativi alla capacità. Se lo stato della capacità è rimasto invariato negli ultimi 14 giorni, non visualizza alcuna informazione. La tabella degli eventi di sistema visualizza i seguenti elementi:

- **Ora** : l'ora in cui la capacità è stata sospesa o ripresa.
- **Stato:** Lo stato della capacità.
- **Motivo della modifica dello stato** : visualizza il trigger dell'evento.

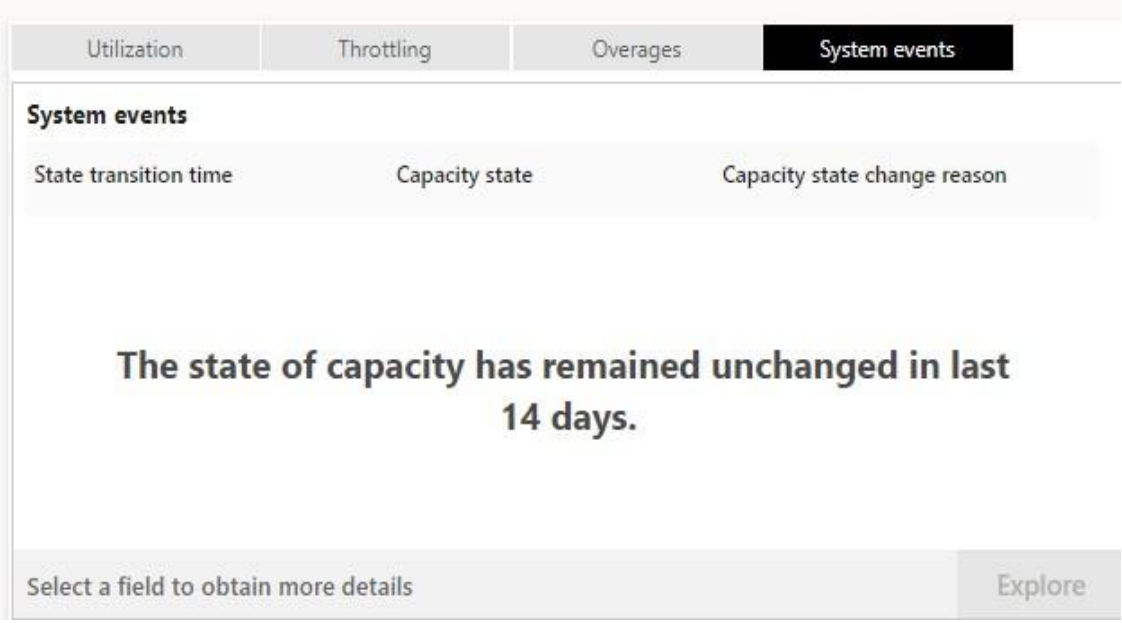

Compute - Matrice

Una tabella matrice che mostra le metriche per ogni elemento della capacità **I colori nella tabella rappresentano il delta delle prestazioni .**Nessun colore - Un valore superiore a -10.

Arancione : valore compreso tra -10 e -25.Rosso : valore inferiore a -25.

Select item kind(s): All Select optional column(s): Multiple selections

Items (14 days)

Workspace	Item kind	Item name	CU (s)	Duration (s)	Users	Successful count	Performance delta	Overloaded minutes	Billing type
My workspace	Pipeline	pipeline1	123,120.0000	2,323.5030	1	1		0.0000	Billable
My workspace	SynapseNote...	Notebook 1	43,400.2590	7,393.3250	1	0		0.0000	Billable
My workspace	SynapseNote...	ConvertToDelta	43,263.3110	6,886.8810	1	0		0.0000	Billable
My workspace	Dataset	LH_Fabric	21,689.8560	769.8280	2	387		0.0000	Billable
My workspace	Lakehouse	LH_practise	20,542.8777	4,904.4630	2	3527		0.0000	Billable
My workspace	SynapseNote...	test 2	19,600.5525	3,158.2830	1	0		0.0000	Billable
My workspace	SynapseNote...	Notebook 2	5,086.0105	1,271.4940	1	0		0.0000	Billable

Fabric documentation : Understand the metrics app compute page - Microsoft Fabric | Microsoft Learn

Autoscale billing for Spark

Generally Available

- **Fatturazione in stile serverless per i job Spark**, in cui i clienti pagano solo ciò che utilizzano a tariffa PAYG
- Gli amministratori possono impostare un limite massimo per l'utilizzo di CU da parte di Spark
- I job vengono fatturati al momento dell'esecuzione, mentre Spark gestisce il limite assicurando che i pool non consumino troppo
- L'utilizzo può essere monitorato in una nuova pagina dell'app Capacity Metrics

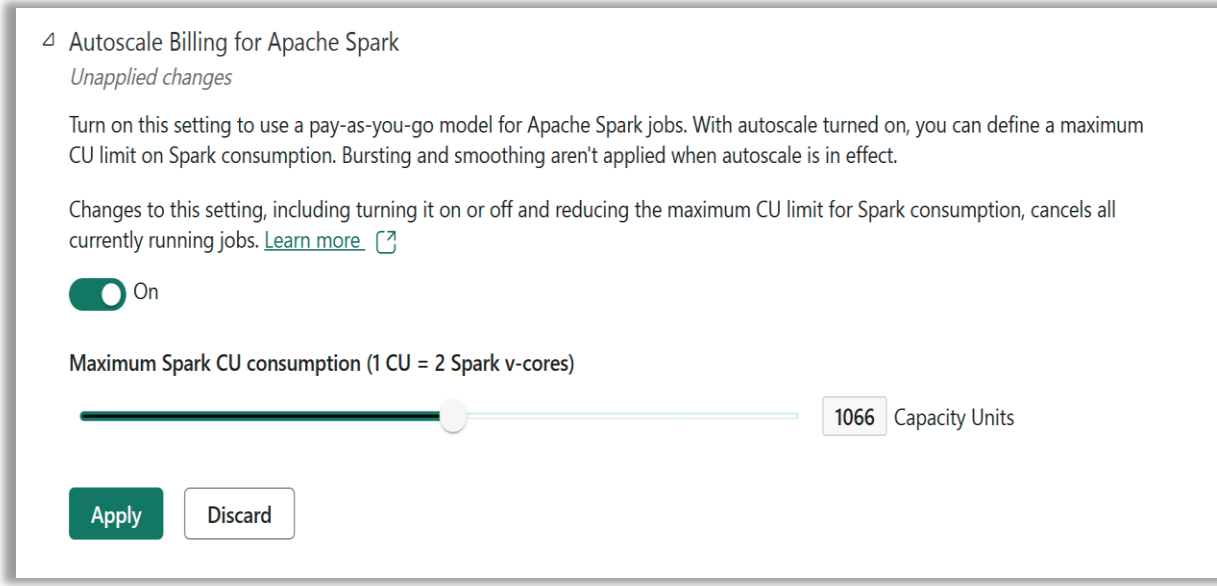

Autoscale billing for Spark in Metric Apps

Generally Available

- Nuova pagina "Autoscale Compute for Spark"
- Mostra le CU di Spark consumate tramite Autoscale
- Facile da monitorare fino al limite di scalabilità automatica configurato
- Ti aiuta a comprendere meglio il calcolo specifico di Spark che verrà riflesso in fattura

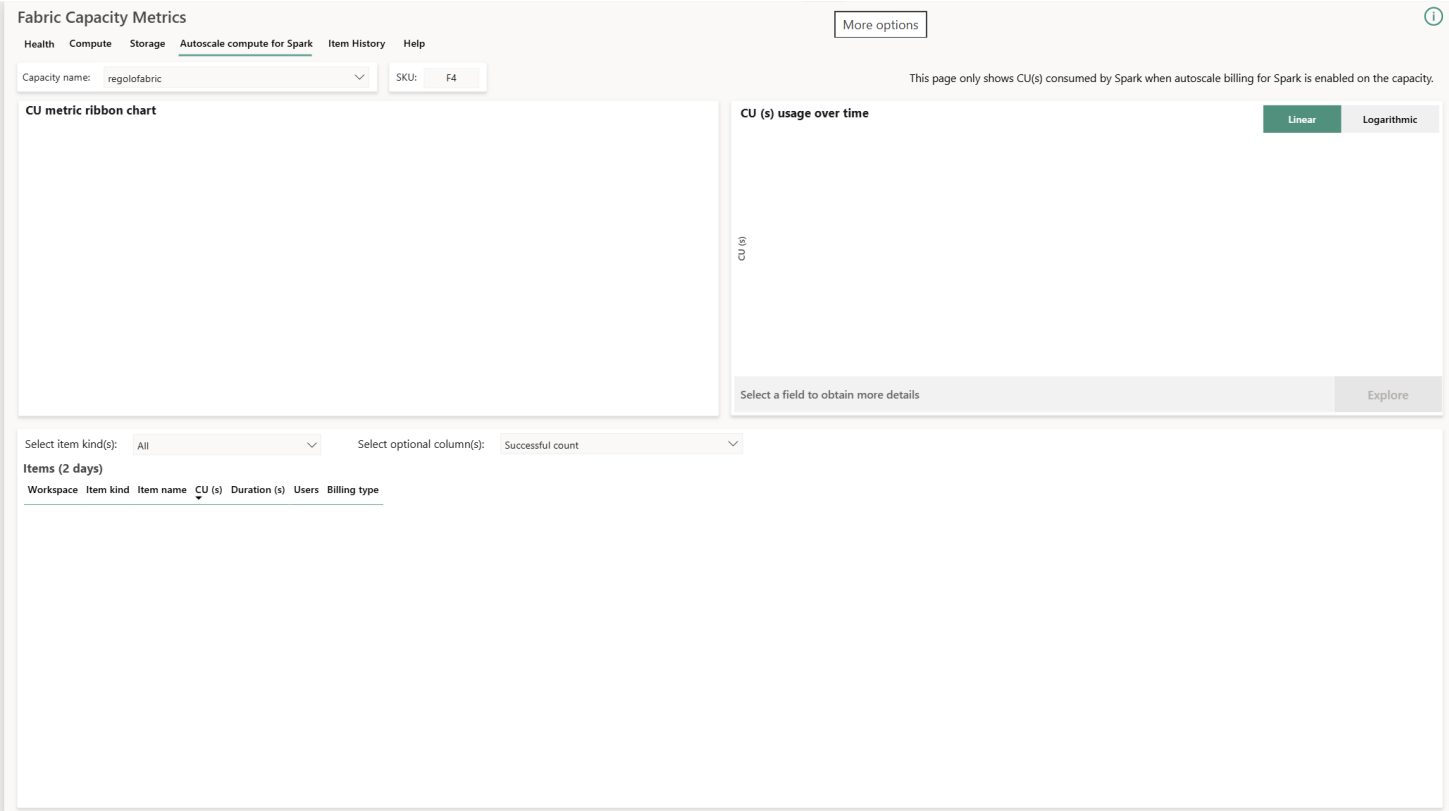

Item History

In Public Preview

- **Visualizza le tendenze di utilizzo del calcolo negli ultimi 30 giorni** tramite elementi visivi interattivi e slicer.
- Consumo di calcolo aggregato
- Cronologia degli elementi
- Offre opzioni di filtraggio granulari: per capacità, area di lavoro, utente, operazione, tipo di fatturazione e intervallo di date

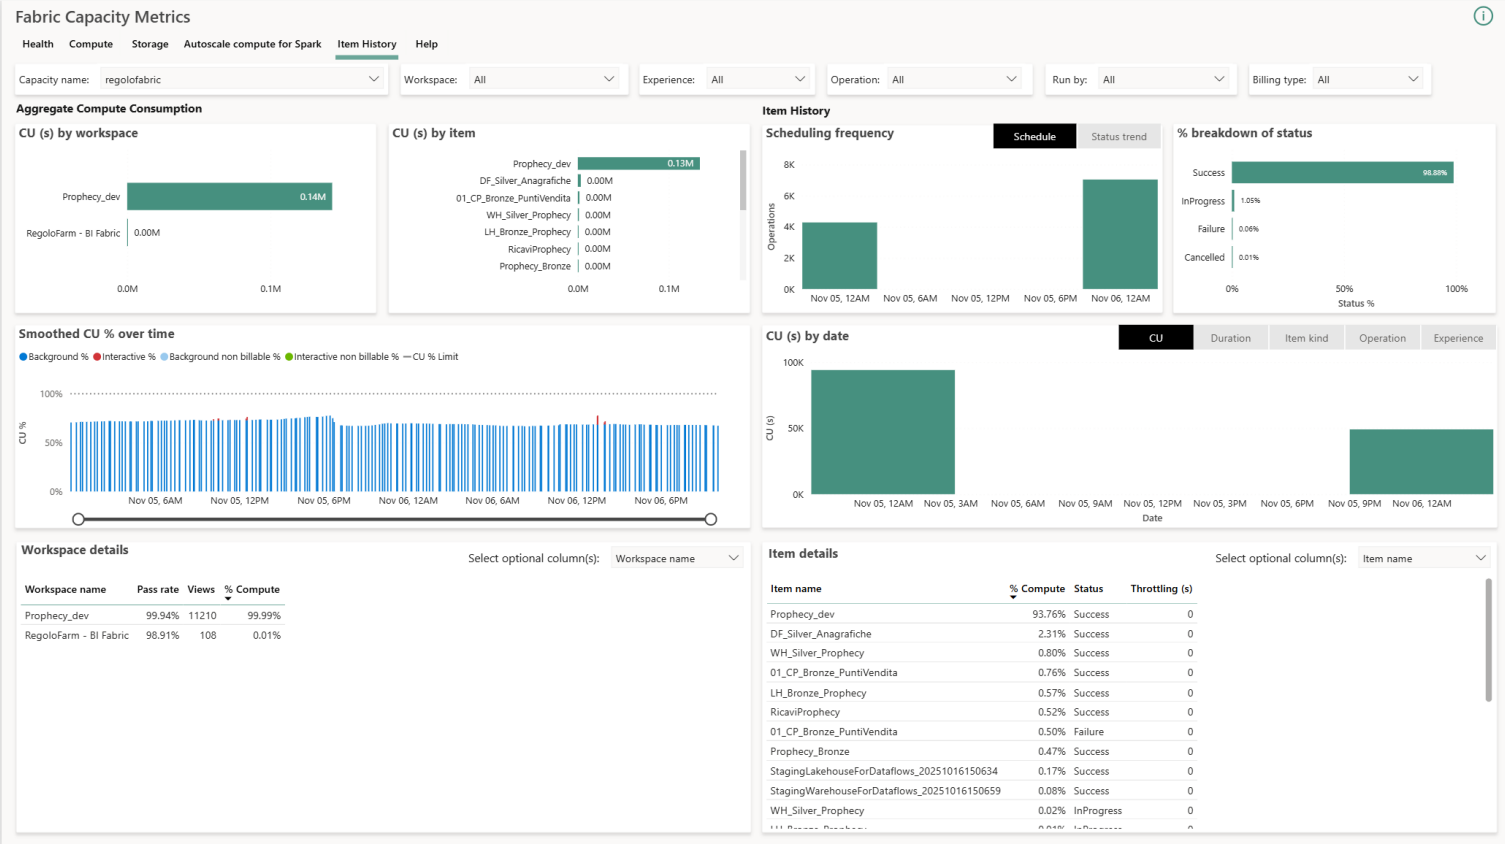

Agenda

- Cosa sono le CU
- Allocazione Dinamica
  - Bursting
  - Smoothing
- Throttling
- Capacity Metric App
- Altri meccanismi di Resource Governator
- Guida alla pianificazione della capacità

Surge Protection V1

Generally Available

- **Evita che si arrivi al 100% della capacità prima di rifiutare le operazioni in background** penalizzando gli utenti del report ad esempio.
- La **soglia di rifiuto delle operazioni in background** determina quando la protezione diventa attiva. La soglia si applica sulla *% di background nelle 24 ore* per la capacità. Quando attiva tutte le richieste di background vengono bloccate.
- La **soglia di ripristino delle operazioni in background** determina quando la protezione cessa di essere attiva. La protezione cessa di essere attiva sulla *% di background nelle 24*

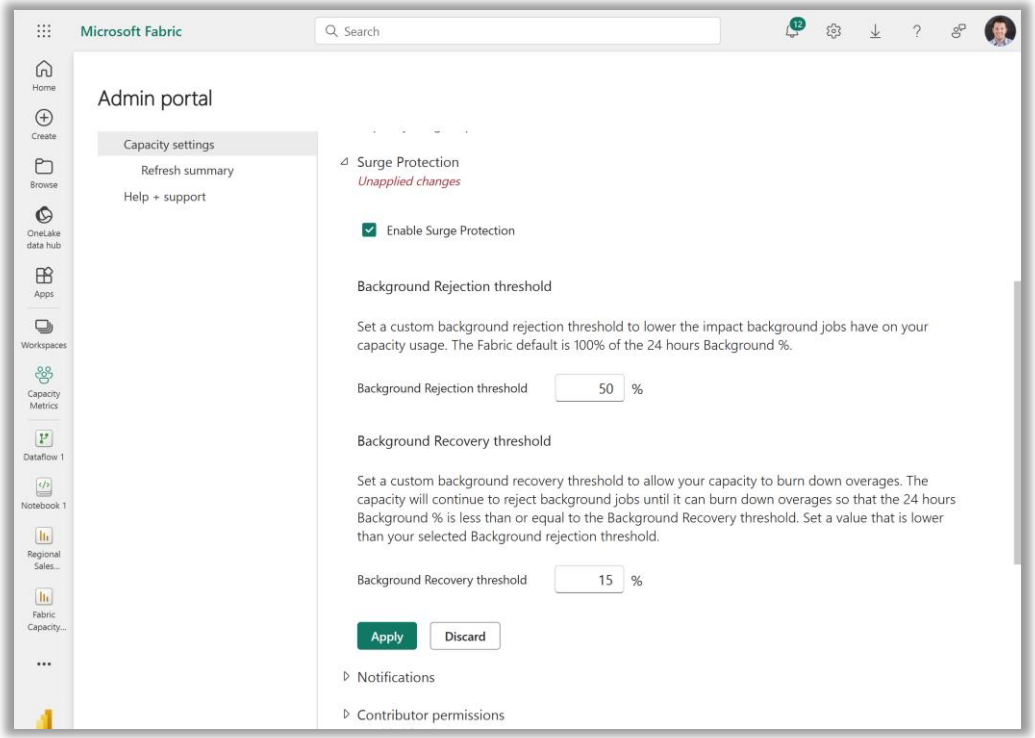

Surge Protection V2

Public Preview coming soon

- Aggiunge limiti di consumo a livello di area di lavoro per impedire che una singola area di lavoro monopolizzi la capacità

- Blocca automaticamente un'area di lavoro quando supera una soglia CU configurabile entro 24 ore

- Auto-riparazione: il blocco viene rimosso automaticamente dopo la durata configurata; gli amministratori possono eseguire l'override in qualsiasi momento

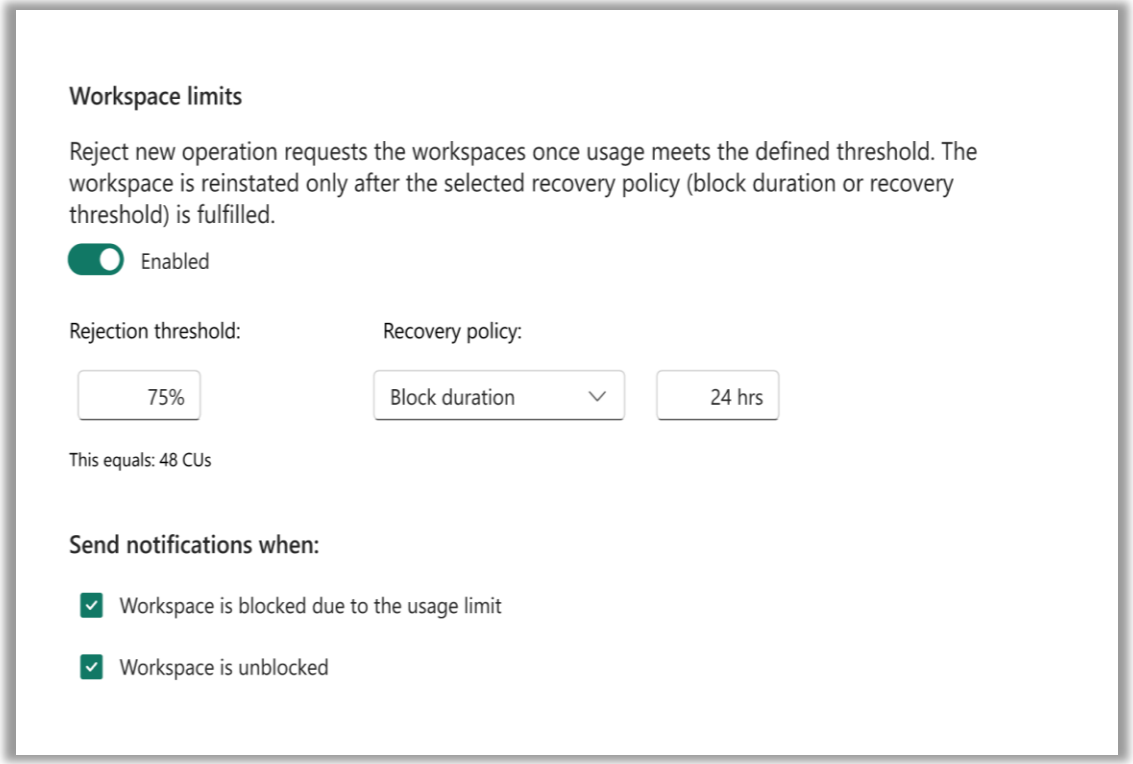

Azure Quota Management (QMS)

Generally Available

- Le quote ottimizzano l'utilizzo delle risorse di Fabric per mantenere le prestazioni e l'affidabilità di Azure e prevenirne l'uso improprio
- I limiti delle quote si basano sul tipo di sottoscrizione e sull'area: è possibile controllare le CU che possono essere provisionate su più capacità in una sottoscrizione
- Migliore allocazione delle risorse con l'aumento dell'utilizzo di Fabric
- Sicurezza e conformità: riduzione del rischio di utilizzo eccessivo non autorizzato

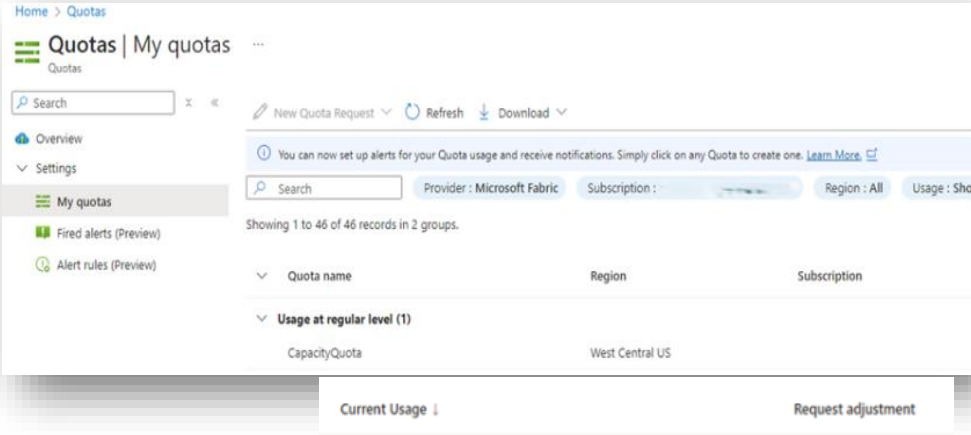

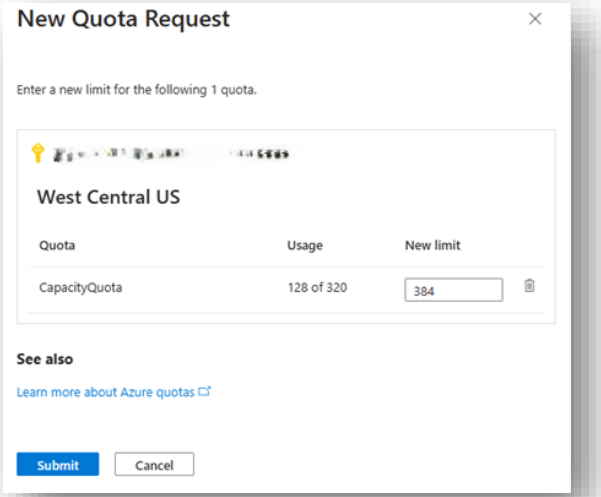

Agenda

- Cosa sono le CU
- Allocazione Dinamica
  - Bursting
  - Smoothing
- Throttling
- Capacity Metric App
- Altri meccanismi di Resource Governator
- Guida alla pianificazione della capacità

Guida alla pianificazione della capacità

Gli amministratori della capacità devono pianificare e stanziare budget per raggiungere due obiettivi:

- **Consolidamento**: condividere in modo efficiente la capacità tra i gruppi per massimizzare l'utilizzo e ridurre al minimo i costi (evitare silos sottoutilizzati).

- **Isolamento**: garantire un isolamento sufficiente affinché l'utilizzo intensivo da parte di un team non influisca sulle prestazioni degli altri (evitare il problema del "vicino rumoroso").

Guida alla pianificazione della capacità

Più unità aziendali usano Fabric, **è necessaria una strategia per allocare la capacità tra di esse.**

Tre modelli comuni sono:

- **Capacità dedicata per reparto/dominio** : ogni team ha la propria capacità Fabric.

- **Capacità condivisa tra i reparti:** i carichi di lavoro di più team vengono eseguiti sulla stessa capacità.

- **Approccio ibrido**: Questi modelli non si escludono a vicenda. Le linee guida Microsoft ci ricordano che "**non esiste una soluzione unica per tutti** ". È comune iniziare con il consolidamento per l'efficienza dei costi, per poi passare a capacità separate man mano che l'utilizzo aumenta o quando specifici team superano l'ambiente condiviso.

Guida alla pianificazione della capacità

Modello	Pro	Contro
Capacità dedicata per reparto	- **Isolamento completo**: le risorse di elaborazione sono esclusive per ciascun reparto. - **Chiara attribuzione dei costi** tramite la fatturazione di Azure. - Ideale per carichi di lavoro mission-critical che necessitano di prestazioni garantite.	- **Potenzialmente costoso se sottoutilizzato** (ad esempio, durante le serate inattive). - **Aumento dei costi amministrativi** (capacità multiple, monitoraggio separato e amministratori).
Capacità condivisa (consolidata)	- Maggiore utilizzo complessivo: le risorse in pool riducono i tempi di inattività. - Consente la collaborazione tra i reparti. - Miglior rapporto prezzo-prestazioni (ad esempio, un F128 rispetto a più F32). - Appiana i picchi di utilizzo tra i team. - Utilizza l'app Fabric Chargeback per distribuire i costi tra reparti, domini o sottodomini.	- **Rischio di contesa**: l'uso intensivo da parte di un team può avere ripercussioni sugli altri. - **Necessita di una governance e di un monitoraggio rigorosi per garantire l'equità**.

Guida alla pianificazione della capacità

Microsoft fornisce un'app Fabric Chargeback per attribuire l'utilizzo della capacità a team, utenti e spazi di lavoro.

Questo strumento consente di creare processi di chargeback per allocare i costi in base al consumo effettivo, in modo che i team rimangano responsabili anche in un modello condiviso.

Una volta identificati i raggruppamenti logici, **dimensionate la capacità in modo appropriato**:

- Fabric Capacity Metrics Utile anche in un secondo momento per il monitoraggio continuo.
- Fabric SKU Estimator fornisce una raccomandazione iniziale di SKU se i dati storici non sono disponibili

Chargeback

In Public Preview

- Aiuta i clienti ad allocare il consumo di CU tra le proprie organizzazioni
- Raccoglie l'utilizzo **(% di utilizzo)**
- per area di lavoro/elemento/utente Le organizzazioni possono confrontare la % di utilizzo in questo report con le fatture per allocare i costi ai proprietari dei contenuti
- Progettato per gli amministratori che per gli utenti delle operazioni finanziarie (FinOps)

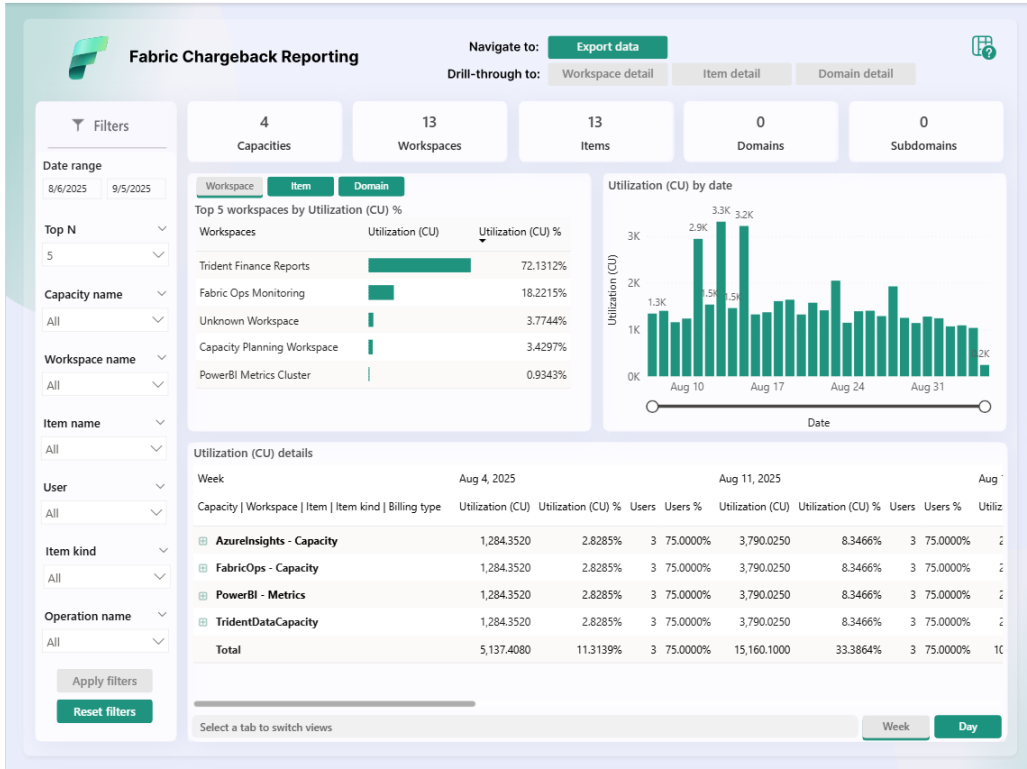

Valore per i clienti

- **Soluzione chiavi in mano per gli ISV che desiderano distribuire equamente il consumo di CU**

Fabric SKU Estimator

In Public Preview

- Stimatore online che fornisce consigli sugli SKU in base all'input dell'utente
- Aiuta le aziende a ottimizzare il piano di infrastruttura dati
- Fornisce stime degli SKU per la migrazione da Synapse Gen2 a Fabric

Valore

- Fornisce stime di capacità personalizzate in base alle esigenze specifiche dei clienti
- Semplifica la stima di uno SKU consigliato quando si inizia con Fabric

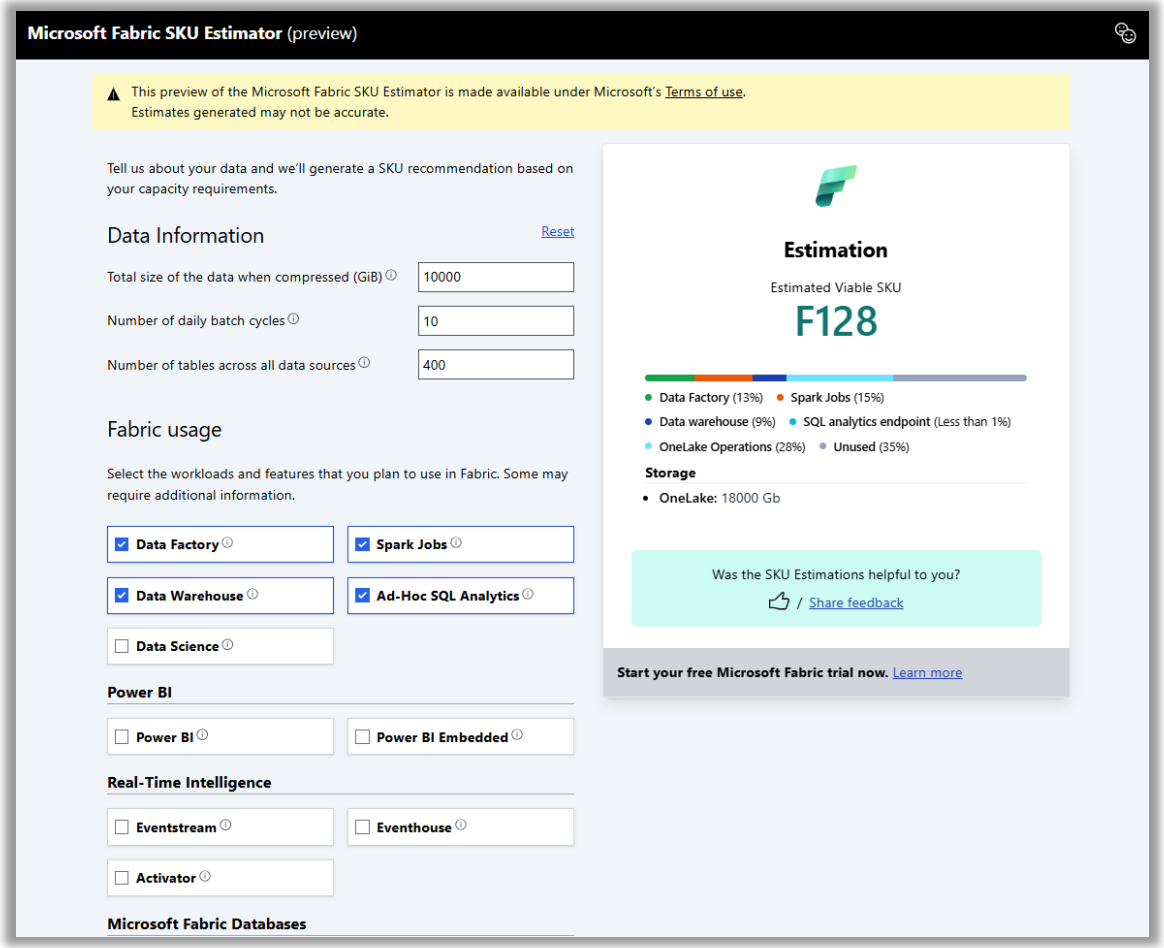

Isolation Strategy

Se si consolidano più team su una capacità condivisa, è importante impostare misure di sicurezza per l'isolamento quando necessario.

Anche con la governance, si possono verificare situazioni in cui un carico di lavoro interferisce con gli altri. Ecco alcune strategie per aiutarti a gestire queste situazioni:

- Isolation Strategy (Try Out Capacity)
- Isolation Strategy (Timeout Capacity)
- Isolation Strategy (Rescue Capacity)

Isolation Strategy (Try Out Capacity)

Quando si implementa una **nuova area di lavoro o un nuovo progetto, distribuirla in una capacità temporanea ridotta** anziché direttamente in una risorsa condivisa.

1. Creare una piccola capacità sku F per provare nuove aree di lavoro/elementi.
2. Valutare il consumo di unità di capacità usando l'app per le metriche.
3. Se accettabile, passare alla capacità di produzione.
4. Se non è accettabile, ottimizzare.
5. Sospendere la capacità di try out quando non è in uso, se possibile.

Isolation Strategy (TimeOut Capacity)

Se un'area di lavoro o un utente **inizia a usare troppe risorse nella capacità condivisa** (causando la limitazione di altri utenti), **spostare temporaneamente tale carico di lavoro in una capacità di piccole dimensioni separata**

1. Creare una piccola capacità sku F.
2. Valutare il consumo di CU usando l'app per metrics.
3. Se il cu per nuovi elementi o aree di lavoro influisce sui carichi di lavoro esistenti (limitazione), spostare la nuova area di lavoro nella capacità di timeout (quarantena)
4. Gli elementi CU elevati o le aree di lavoro (vicini rumorosi) condividono capacità più piccola (oppure è possibile sospenderla dopo lo spostamento).
5. Prendere nota delle soglie del carico di lavoro prima dello spostamento.

Isolation Strategy (Rescue Capacity)

Mantenere una **capacità di standby** pronta per gestire picchi occasionali. Ad esempio, una capacità in genere sospesa può essere ripresa rapidamente durante un'emergenza. Se un team ha un lavoro urgente che sta sovraccaricando la capacità condivisa, passare l'area di lavoro del team alla capacità di standby per il periodo di picco.

1. Creare una capacità sku F; tenerla in pausa.
2. Valutare il consumo di cu usando l'app per le metrics.
3. Se cu per nuovi elementi influisce sui carichi di lavoro prioritari, avviare la nuova capacità.
4. Spostare l'area di lavoro prioritaria in una nuova
5. Risolvere i problemi relativi al nuovo contenuto, quindi riportarlo alla capacità originale e sospendere quella nuova.
6. Prendere nota delle soglie del carico di lavoro prima dello spostamento.

Feature Roadmap

Feature Theme	Feature Name	Feature Highlight	Status	ETA
Capacity Resource Governance	Fabric Copilot Capacity (FCC)	Allows orgs to assign a dedicated capacity to cover Copilot usage for selected users	GA since Feb 2025	
	Spark Autoscale	Optimizes performance and cost by scaling resources up during peak activity and down when idle or underutilized	GA since Jul 2025	
	Surge Protection V1 New!	Prevents background operations from overwhelming your compute resources	GA since Jun 2025	
	Surge Protection V2	Prevents a single workspace from using up all your compute resources	Private Preview	Public Preview in < 3 months
	Throttling Protection (Maybe)	Automatically prevents throttling by billing overages and accumulated usage	Limited Private Preview	TBD
Capacity Observability	Chargeback Reporting New!	Helps Tenant and Capacity Admins allocate costs fairly across their organization	Public Preview	GA in < 3 months
	Historical Analysis New!	Enables users to track and analyze capacity usage trends over time.	Public Preview	GA in < 6 months
	Timepoint Drill	Allows users to analyze compute unit (CU) usage at a granular timepoint level	Public Preview	GA in < 6 months
	Cross Capacity Metrics	Provides a single pane of glass to monitor the health and usage of all capacities in a tenant	Private Preview	Public Preview in < 3 months
	Capacity Events in RTH	Real-time telemetry stream that exposes the same data in the Metrics App, but with low latency, programmable access, and custom routing capabilities	Private Preview	Public Preview TBD
	Fabric SKU Estimator			

DATA SATURDAYS

Innova community